揭示 OKS-mAP 的评估盲区：面向遮挡、关节角度与时序稳定性的二维人体姿态估计统一评估协议

樊一凡
太原扬帆学校国际部
中国 · 太原

摘要—二维人体姿态估计的主流评估协议——基于对象关键点相似度（OKS）的 mAP——对三个对下游应用至关重要的性质不敏感：聚合分数不区分可见与遮挡关键点；不度量关节角度误差；对无追踪逐帧推理输出的时序稳定性保持沉默。本文提出一个统一的补充评估协议，包含三个模块：（M1）按真实可见性标注（v）分层的 OKS-mAP，并以 $\Delta_{\text{occ}} = \text{mAP}(v{=}1) - \text{mAP}(\text{full})$ 量化聚合指标对遮挡特定差异的掩盖程度；（M2）以真实标注（GT）关键点推导的关节角为参照的角度误差（RMSE/MAE/P95）与膝内扣检出一致性（Cohen's κ）；（M3）无追踪逐帧推理设定下的帧间位移、中值滤波残差抖动与跳变率，以及 OneEuro 平滑前后的对比。我们在四个公开数据集（COCO val2017、CrowdPose、OCHuman、PoseTrack18）上对跨越两个架构族的四个模型——官方 YOLO11s-pose 与一个遮挡域数据微调模型，以及基于 Transformer 的 ViTPose-B/L——执行了协议，全部跨架构比较均在统一的检测器无关 GT-bbox oracle 协议下进行，全部指标由开源 harness 单次推理统一产出。所有模型-数据集组合的 Δ_{occ} 均为负（-0.19 至 -0.47）：聚合 mAP 在每一个受测组合、两个架构族中都高估了遮挡场景的表现。角度误差在所有受测组合的遮挡层均被放大；在遮挡域数据集上，角度指标揭示了模型之间的显著差异，而聚合 mAP 无法定位这一差异——其中包括统一 oracle 协议下的一例：较小的遮挡域训练模型在遮挡肘部层显著比更大的 Transformer 更准。在 PoseTrack18 val 的已匹配保留段子总体上（约 53% 标注帧），两种协议下两个 YOLO 模型对的原始时序抖动均未发现差异；像素域 OneEuro 平滑以零匹配口径 AP 代价（$|\Delta\text{AP}| \le 0.0002$）将两模型的跳变率降低 9–10%；oracle 协议进一步证明残余高频抖动在移除检测器后依然存在（并非检测器内生），且统一协议下 Transformer 模型对的跳变率显著低于 YOLO 模型对，平滑域结论跨架构复现。相关性分析表明分层 mAP 与全量 mAP 高度一致（符号一致性 $\tau_s = 1.0$，12/12 对）——其价值在于量级诊断而非重排名——而角度指标（尤其膝角）的差值向量与全量 mAP 的排序并不完全一致，提示其携带部分独立信息（描述性 $n = 6$，第 5.4 节）。协议与 harness 已开源，定位为 OKS-mAP 的补充而非替代。

关键词—人体姿态估计；评估协议；遮挡；关节角度；时序稳定性；OKS mAP

I. 引言

二维人体姿态估计是计算机视觉的基础任务，其输出支撑动作识别、运动分析与实时健身矫正等下游系统。对这些应用而言，基准分数与实际可用性之间的落差比平均精度本身更值得关注：一个在基准上排名领先的模型，可能在人员遮挡、快速运动或需要精细关节角度判断的场景中明显更差——而这一差异在主流指标中不可见。盲区究竟会改变模型排名、还是只掩盖量级，本身是一个经验问题；本文对其检验（RQ1），并发现对受测的各模型对而言，架构族内排名稳定而量级差异显著（第 5.4、5.5 节）。

事实标准评估协议是 COCO keypoints 协议定义的 OKS-mAP [1]。它以对象关键点相似度（OKS）匹配并计分，在整个测试集上聚合为一个标量。这一设计存在三个盲区。第一，OKS 聚合忽略关键点可见性：可见（v=2）与遮挡（v=1）关键点被等权平均进同一分数（缺失关键点 v=0 被排除在 OKS 平均之外），遮挡特定的精度差异被平均稀释。第二，协议不度量关节角度：OKS 惩罚的是关键点像素级位置误差，而下游应用（如运动矫正）关心的是由这些关键点推导出的关节角是否准确——两者并非线性对应。第三，协议对时序行为失明：多数系统对视频逐帧独立推理，帧间输出的抖动直接决定下游消费端的观感，而静态图像协议对此完全沉默。已有工作对上述问题各有单点回应——OCHuman 按遮挡级别组织评测 [2]；PoseTrack 与 SmoothNet 分别以跟踪指标（MOTA/MOTP）和时序平滑度指标（逐关节加速度幅值 Accel）延伸了静态协议 [3], [15]；生物力学领域验证过 markerless 姿态估计的关节角度 [4]–[6]——但缺少一个统一、可复现、跨数据集的补充协议，也没有任何基准数字说明这三个盲区在真实模型上的量级。

本文提出一个三模块统一补充评估协议（第 3 节），并

开源其执行层 eval harness：单次推理同时产出官方指标与协议指标，配三门禁自检。我们在四个公开数据集上以两个代表性模型执行了协议（第 4–5 节），回答五个研究问题：

- **RQ1（遮挡）**：全量 OKS-mAP 在多大程度上掩盖遮挡特定的精度差异？按可见性分层后模型排名是否改变？
- **RQ2（角度）**：关节角 RMSE 能否提供 OKS-mAP 之外的区分信息？角度误差是否被遮挡放大？
- **RQ3（时序）**：无追踪逐帧推理下，模型的时序稳定性差异有多大？平滑能否以可接受的精度代价换取稳定性？
- **RQ4（协议精简）**：三模块指标之间以及与全量 mAP 的相关性如何？是否存在冗余？
- **RQ5（架构普适性）**：在检测器无关的 GT-bbox oracle 协议下，三个盲区对 Transformer 类模型是否依然存在？另一架构族内的模型排名是否会重排？

本文贡献有三点：（1）据我们所知，首个将遮挡分层、角度误差与时序抖动统一在一个协议下的补充评估方案，含明确的统计口径（bootstrap 置信区间）与跨数据集一致的分层规则；（2）开源 harness 与全部原始预测，任何新模型可在四个数据集上单次跑出全部协议指标；（3）来自两个架构族、四个模型的完整基准数字——包括一个把姿态头与检测器隔离的检测器无关 oracle 协议——据我们所知首次量化 OKS-mAP 三盲区的量级（如 oracle 协议下 COCO 上 Δ_{occ} 达 -0.47）。

II. 相关工作

姿态估计评估协议。 COCO keypoints 协议以 OKS 为核心，自 2014 年起是该领域的事实标准 [1]；其前身 MPII 上的正确关键点百分比（PCK） [16] 与本文各模块所针对的结构相同：整个测试集上的单一聚合量。PoseTrack 将评估延伸到视频多人姿态跟踪，建立以 MOTA/MOTP 为核心的跟踪口径 [3]；SmoothNet 更进一步，提出逐关节加速度幅值（Accel，单位像素/帧 ^{2}）作为视频姿态的时序平滑度指标，并在滤波前后对比中沿用该口径 [15]。本文 M3 与 Accel 互补：Accel 度量帧间二阶差分的大小，而本文的帧间位移与中值滤波残差分别度量位置波动与高频噪声，并额外报告平滑的精度（AP）代价。数据侧，CrowdPose 与 OCHuman 提供真实标注的可见性/遮挡标签（CrowdPose 的 v=1；OCHuman 的三级遮挡）[2], [7]。这些工作的共同边界是：各自在单一数据集、单一维度上做单点改进，没有形成跨数据集统一口径的补充协议。

遮挡鲁棒性评估。 已有工作尝试量化遮挡对姿态估计的影响：Ghafoor 与 Mahmood 通过合成移除关节构造三组实验，量化遮挡对 3D 姿态误差的影响 [8]；后续工作在合成遮挡下的鲁棒性评测 [9] 与可见性感知的视频遮挡基准 [10] 上延续这一思路。与本文的差异：这些工作使用合成遮挡或非真实标注的分层，且集中于单数据集、单指标；本文直接利用三个数据集的真实 v 标注跨数据集分层，并对照全量 mAP 报告 Δ_{occ}。

关节角度验证。 生物力学与运动科学领域有一条 markerless 姿态估计效度研究线：Turner 等在 89 段阻力训练视频上以 BlazePose 关键点重建关节角轨迹，按逐帧 RMSE 对照参考动作评估动作技术质量 [4]；Panconi 等验证 DeepLabCut 在步态分析中的关节角 [5]；Pemasiri 等构建面向生物力学解释的步态分析框架 [6]。这些研究回答的问题是「估测角度是否等于临床/标记点金标准」（效度），需要专门的标记点或专家标注。本文不重复效度验证，而是把 GT 推导角度用作模型间比较的协议指标。两条线互补而非竞争（第 6 节详述边界）。膝内扣阈值取文献量级参照：侧向下台阶测试的额状面投影角（FPPA）16.0–17.4° [11]。

时序一致性与平滑。 无追踪逐帧推理的时序不一致问题由 Deep Video Prior 等从通用层面讨论 [12]；工程实践中广泛采用 OneEuro 因果滤波平滑关键点轨迹 [13]。本文把「无追踪原始输出的稳定性」本身变成协议指标，并对比两种滤波域（归一化坐标域与像素域）对抖动指标与 AP 的联合影响——这一对比揭示了滤波域选择如何决定平滑的收益与代价。

III. 协议设计

A. 总览

协议由三个模块加一个统计层组成，全部建立在 COCO 17 关键点定义与 OKS 口径的公共基础之上。表 I 给出总览。

B. *M1*：遮挡分层 *mAP*

分层口径。 每个 GT 关键点按其可见性标签 v 归层：v=2 可见、v=1 遮挡、v=0 缺失。层内独立计算 OKS AP。v=0 层只报告、不参与排名（该层关键点无法被估计，分数接近零；保留该层作为协议完整性的证据）。每个数据集在转换到 COCO17 后保留真实 v 标注：CrowdPose 官方 14 点映射为 COCO 索引 5–16（head_top 与 neck 两点丢弃——属映射裁剪而非可见性标签破坏，12 个映射点的 v=1 标签完整保留）；OCHuman 官方 test 标注本身即 COCO17 格式，直通保留；COCO val 本身含 v=1 标注（占关键点 7.75%）。

表 I
协议总览。

模块	指标	数据	回答
M1 遮挡分层	v 分层 mAP^{50-95}(P) + Δ_{occ}	CrowdPose val / OCHuman test / COCO val	RQ1
M2 角度误差	肘/膝关节角 RMSE/MAE/P95 + 膝内扣检出一致性（κ）	同 M1（角度由 GT 推导，零额外标注）	RQ2
M3 时序抖动	帧间位移 / 抖动 / 跳变率，OneEuro 前后	PoseTrack18 val（无追踪逐帧推理）	RQ3
统计层	10k bootstrap CI + 符号一致性 τ_s + Spearman ρ	三模块结果	RQ4、模型比较

计算口径。沿用 pycocotools 2.0.11 的 keypoints 协议（官方发布数背后的口径）：OKS 阈值 0.50:0.95 共 10 档取均值；num_keypoints=0 的 GT 标为 ignore；maxDets=20。分层只改变统计、不改变匹配逻辑：人员匹配（TP/FP 判定）仍按全关键点 OKS 进行，层 AP 只累计该层 GT 关键点的 OKS 贡献。三门禁保证实现正确：门禁 1 与官方 pycocotools 2.0.11 对拍（差 ≤ 0.0001）；门禁 2 合成自检（(i) GT 推导角直通预测路径，RMSE $< 10^{-9}$；(ii) 二值化膝内扣序列与 GT 完全一致时灵敏度 = 特异度 = 1；(iii) 常数轨迹的位移与抖动恒为 0；(iv) 常数序列经 OneEuro 后保持不变）；门禁 3 全 v=2 合成数据下 v=2 层 AP 恒等于全量 AP、分层开关不改变全量 mAP。

解释性证据。层 AP 的召回分母为全部 GT 人员，因此没有该层关键点的人员永远无法为该层贡献 TP。故每层同时报告「该层 GT 关键点占比」(gt_frac) 与「拥有该层关键点的 GT 人员占比」(gt_person_frac)。特别地，CrowdPose 官方标注把可见点几乎全部标为 v=2（遮挡点聚集于 v=1），而层 AP 的召回分母为全部 GT 人员——没有该层关键点的人员永远无法为该层贡献 TP（gt_person_frac 仅 0.591），其 v2 层 AP 被系统性低估。这一分母偏置同时作用于 v2 层与全量 AP，在差值 $\Delta_{\text{occ}} = \text{mAP}(v{=}1) - \text{mAP}(\text{full})$ 中相互抵消——这正是 CrowdPose 上跨层比较改用 Δ_{occ} 的原因。

主指标。 $\Delta_{\text{occ}} = \text{mAP}(v{=}1\ ) - \text{mAP}()$；为负表示全量指标高估遮挡场景表现。两项均在相同的图像域、相同的全量 GT 人员集上计算（v=1 层的召回分母即全量 GT 人员集，见解释性证据），因此 Δ_{occ} 隔离的是遮挡层的贡献缺口，而非分母变化。逐层 mAP 与 gt_frac 一并报告。

表 II
关节角定义（COCO17 索引，0-based）。

关节	顶点	端点（近端, 远端）
左肘	7	5, 9
右肘	8	6, 10
左膝	13	11, 15
右膝	14	12, 16

C. *M2*：角度误差

关节角定义。以 COCO17 索引定义四个关节（表 II）；内角 $\theta = \arccos\big((\mathbf{a}\cdot\mathbf{b})/(|\mathbf{a}||\mathbf{b}|)\big)$，其中 **a**、**b** 分别为顶点到近端、远端的向量。$|\mathbf{a}|$ 或 $|\mathbf{b}| < 10^{-6}$ 的实例剔除。

有效性掩码。GT 角度：三个 GT 点 v 均 >0 才计入；预测角度：同三点 GT v 均 >0 且预测置信度 >0 才计入——保证 GT 与预测在同一域上可比，避免偏向缺失预测。逐实例误差 $e = \theta_{\text{pred}} - \theta_{\text{gt}}$；报告 RMSE、MAE 与 P95，按顶点 GT 可见性分 v=2/v=1 两层报告，与 M1 联动。

聚合与数值条件。 RMSE 采用全局平方误差池化：$\text{RMSE} = \sqrt{\frac{1}{n}\sum_i e_i^2}$，在全部有效实例上计算（左右侧在实例级合并，绝不先按图或按侧取 RMSE 再平均）。反余弦参数在计算角度前裁剪到 $[-1, 1]$，防止 0°/180° 附近的浮点漂移。因两模型的有效实例集可能有细微差异，我们在两模型集合的交集上重算了全部 24 个（数据集, 关节, 层）RMSE 比较作为稳健性检验：24 个显著性判定全部不变（完整数字见仓库），说明比较结果不是覆盖差异的产物。

膝内扣检出一致性。膝内扣角 ϕ 定义为髋 → 膝向量与髋 → 踝向量在图像平面的夹角（膝点偏离髋-踝轴线的程度），仅对三点 v 均 >0 的实例计算。ϕ_{pred} 与 ϕ_{GT} 按阈值 τ_φ 二值化（默认 $\tau_\varphi = 15°$，敏感性分析 $\tau_\varphi \in \{10°, 17°\}$），以 GT 为金标准报告检出灵敏度、特异度与 Cohen's κ。两点澄清：不报告绝对检出率（静态数据集视角混杂，绝对率无意义；一致性才是协议能测的量）；ϕ 是任意视角下的 2D 图像平面代理量，而 FPPA 文献值来自标准化正面机位 [11]——本文数据集视角混杂，故 τ_φ 仅取文献量级参照，不具临床诊断含义。

D. *M3*：时序抖动

数据与匹配。 PoseTrack18 val 视频逐帧独立推理（无追踪、无跨帧信息）；每帧预测与 GT 按全关键点 OKS 做匈牙利匹配（口径同 M1）。帧间隔 >1 即断段；仅保留连续 ≥ 10 帧有匹配的轨迹段。这一保留规则相当严格：94–95% 的原始轨迹段不足 10 帧而被丢弃，保留段覆盖标注帧的 53.1–53.4%（round5-3：704 段 / 4,767 帧；YOLO11s-pose：

728 段 / 4,739 帧）；此外有 16.3–20.1% 的 GT 人员实例从未匹配到任何预测。因此 M3 数字描述的是「已匹配、已保留」的子总体，而非整个视频。所有位移按 GT 人框尺度 $s_t = \sqrt{w \cdot h}$ 归一化（与 OKS 尺度口径一致）。

三**指标**（逐关键点、逐轨迹段计算后取均值）：

1) 帧间位移 $d_t = \|\mathbf{p}_t - \mathbf{p}_{t-1}\|_2 / s_t$：报告均值与 P95；
2) 抖动 $j_t = \|\mathbf{p}_t - \hat{\mathbf{s}}_t\|_2 / s_t$，$\hat{\mathbf{s}}$ 为因果 5 帧中值滤波后的轨迹：专测高频噪声（核心指标）；
3) 跳变率：$d_t > \tau_j$ 的帧占比，默认 $\tau_j = 0.05$（人框尺度的 5%），敏感性 $\tau_j \in \{0.10, 0.20\}$。

OneEuro 前后对比。离线对 $\mathbf{p}_t$ 施加因果 OneEuro 滤波，参数固定为 Casiez 默认值（min_cutoff= 1.0、beta= 0.007、d_cutoff= 1.0）[13]。平滑后重算三指标与匹配口径 AP，报告精度代价。滤波域双口径：归一化坐标域（q 域，协议原设计）与像素域。实证发现（两模型一致）：q 域滤波在反归一化时把 GT 人框的逐帧尺度噪声（$|s_t/s_{t-1} - 1|$，中位数 0.97%，P95 8.1%）重新注入像素域，导致抖动指标不降反升、AP 微降；像素域直接滤波零 AP 代价且三指标全面下降。默认参数下的结论对调参不敏感：在 12 点网格（min_cutoff $\in \{0.5, 1, 2, 4\}\times$ beta $\in \{0.001, 0.007, 0.05\}$）上，每一个像素域设置都使两模型的全部七个 M3 指标降至原始基线以下，且 $|\Delta\text{AP}| \le 0.0004$；q 域在最强平滑下最多损失 0.0071 AP（网格数字见仓库）。**本文采用像素域为主口径**，q 域作为敏感性口径如实报告（表 VI 双列）。

E. 统计口径

- 模型比较：M1/M2 图像级、M3 轨迹段级重采样，10,000 次 bootstrap（seed 42）；报告差值 Δ 的 95% 百分位 CI，以 CI 是否包含 0 判断显著性。M1 为配对设计（共享图像域 = 两模型 GT 图与预测图的并集）；M2/M3 的有效单元集随匹配结果不同，采用独立重采样，协议中已注明。
- 比较清单在实验前固定（2 模型 × 3 数据集 × 层/关节/指标，另加 RQ5 的 oracle 清单 2 个 Transformer 模型 × 3 数据集 × 层/关节）；每项均报告 CI，不挑选有利结果。
- RQ4（协议精简）：在（数据集 × 层）单元上，计算协议指标差与全量 mAP 差的符号一致性 $\tau_s = (C - D)/(C + D)$（C 同号对、D 异号对），并计算两组差值向量之间的 Spearman ρ。τ_s 统计全部两两单元比较，排除全量 mAP 差相同的单元对（并列，符号一致性无定义）：$n = 6$（3 数据集 × 2 层）时，15 个两两比较减去 3 个同数据集层对 = 12 个报告对；关节级（$n = 24$：3 数据集 × 4 关节 × 2 层）时，276 个两两比较减去 84 个同数据集同关节层对（3×28）= 192 个报告对。两项分析均为探索性，样本量已在正文注明。$n = 6$ 个单元仅包含每个指标 3 个独立的数据集级取值（两模型共享同一批三个数据集），因此有效单元是数据集，相关分析属探索性而非验证性。所有区间均为逐比较、未做多重校正的 95% CI；显著性仅作辅助，核心结论以三数据集方向一致性与效应量支撑（核心比较族的 FDR 敏感性分析见附录 A 表 A14）。

F. Harness 与可复现性

执行层为开源 eval harness：`model.val(save_json=True)` 单次推理同时产出官方指标与预测 JSON；M1/M2/M3 引擎纯离线（NumPy）计算，不占 GPU。三门禁保证口径实现正确（见 3.2 节）。可复现契约（环境、权重、数据、逐条命令、口径说明）见仓库 REPRODUCIBILITY.md；全部模型权重（含 round5-3 与 YOLO-oracle 变体）经仓库 GitHub Release 分发，校验和与获取方式记录于 REPRODUCIBILITY.md。协议 JSON 契约（schema_version=1）可供下游作图与二次分析。harness 与本文源码开源：https://github.com/fanyifan090409-dev/pose-eval-harness 与 https://github.com/fanyifan090409-dev/elthan-pose-research；训练分支（基于 ultralytics）见 https://github.com/fanyifan090409-dev/elthan-pose。

IV. 实验设置

数据集。四个公开数据集：COCO val2017（通用域对照；v 分布 55.4%/7.8%/36.8% 对应 v=2/1/0）、CrowdPose val（拥挤/遮挡域；v=1 为真实遮挡标记；分布 22.5%/30.8%/其余）、OCHuman test（重度遮挡域；分布 69.2%/14.3%/其余）、PoseTrack18 val（视频时序；170 视频 / 8,923 标注帧；GT $v \in \{0, 1\}$，其中 v=0 即 (0,0) 占位）。所有数据集统一为 COCO17 关键点格式。PoseTrack 经 MPII 官方学术许可获取，仅用于学术评估。

模型。两个基准模型：（1）官方 YOLO11s-pose 预训练权重 [14]；（2）round5-3——作者训练流水线第 5 轮数据配置第 3 个检查点的产物（名称沿用内部运行编号），在 COCO、MPII、CrowdPose、OCHuman 等公开数据上微调 YOLO11s-pose 所得，代表遮挡域数据训练。两者同架构、同推理配置，仅训练数据不同，适合检验协议对训练数据差异的敏感性。round5-3 的训练数据仅限训练划分（COCO train2017、MPII train、CrowdPose train、OCHuman train，另加受控比例的 OpenThermalPose train [18]）；本文所用的

四个评测划分（COCO val2017、CrowdPose val、OCHuman test、PoseTrack18 val）均未出现在其训练数据中，协议数字无泄漏。另有两个模型把基准扩展到跨架构：（3）ViTPose-B 与（4）ViTPose-L [17]，同架构族、不同容量的自顶向下 Transformer 模型（ViT-B/L 主干），在检测器无关的 GT-bbox oracle 协议下评测。为使每一项跨架构比较都是同协议检验，两个 YOLO 模型也在 oracle 协议下额外评测：每个 GT 人框裁剪、letterbox 到 640×640、不翻转直接送进单阶段模型（Transformer 的 UDP 预处理保持 256×192 加翻转测试）。四个模型由此覆盖两个架构族，支持三组比较：YOLO 族内的训练数据效应（RQ1–RQ4）、ViTPose 族内的架构容量效应（RQ5），以及统一 oracle 协议下的跨架构效应（RQ5）。该协议下四个模型同台比较；YOLO-oracle 变体仅在预处理上不同（GT 人框裁剪加 letterbox，而非 UDP 加翻转），第 5.5 节报告并讨论其影响。

推理与口径。输入 640×640，逐帧独立推理，save_json 保存预测。所有 mAP 数字采用 pycocotools 2.0.11 官方发布数口径；该口径的 OKS 双倍 bbox 兜底规则：GT 关键点 $vg>0$ 但关键点面积为 0（$k_1=0$，即 COCO (0,0) 占位）时，以 bbox 推导的尺度计分而非直接丢弃。注意该口径与 ultralytics 内部评估器可相差 20 点以上（根源：num_keypoints=0 的 GT 标 ignore、OKS 双倍 bbox 兜底、maxDets=20）；论文每张表均注明口径。PoseTrack 无官方 pycoco 对照，其官方指标仅报告内部评估器口径（round5-3 0.1085 / YOLO11s-pose 0.1213 mAP^{50-95}(P)）。门禁 1（与官方库对拍）在全部六个模型-数据集单元上实测 ≤ 0.0001（五个单元精确为 0）。

检测器无关 oracle 协议。ViTPose 模型直接用每个 GT 人框作为检测结果——每个 GT 标注出一个预测——检测器误差完全不进入管线；预处理遵循官方自顶向下口径（UDP 仿射变换、256×192 输入、flip test）；PoseTrack 的 657 个退化 0×0 GT 框在源头跳过。oracle 协议隔离姿态头：所有残余误差都归因于关键点定位与可见性推理，而非检测。门禁 1（与 pycocotools 2.0.11 对拍）在全部六个 ViTPose 模型-数据集单元上精确为 0；ViTPose-B 的 COCO 全量 AP（0.7676）较官方论文数字（75.8，检测框输入口径）高 0.96 点——方向与量级符合预期，因为 oracle 以 GT 人框替换检测框、移除了检测误差 [17]。oracle 与检测式之间的跨族比较仅作方向性参考（第 5.5 节）。

表 III

M1 分层 mAP^{50-95}(P)（pycocotools 2.0.11 口径）。粗体 = 显著占优（bootstrap CI 不含 0）。gt_frac = 该层 GT 关键点占比；gt_person_frac = 拥有该层至少一个关键点的 GT 人员占比（两者均为 GT 属性，两模型相同）。Δ_{occ} = mAP（v=1 层）− mAP（全量），同一全量 GT 人员集上计算（3.2 节）；其 bootstrap CI 见附录 A。— = 该层不定义。CrowdPose 官方标注把可见点几乎全部标为 v=2，叠加全员召回分母（gt_person_frac 0.591）使其 v2 层 AP 被系统性低估；跨层比较使用 Δ_{occ}（分母偏置在差值中抵消）。

数据集	层	round5-3	YOLO11s-pose	Δ_{occ} (r5-3)	Δ_{occ} (YOLO)	gt_frac	gt_person_frac
COCO val	full	0.5712	**0.5816**	—	—	1.000	1.000
COCO val	v=2	0.5637	**0.5728**	—	—	0.554	0.988
COCO val	v=1	0.1747	0.1719	−0.3965	−0.4097	0.078	0.564
COCO val	v=0	0	0	—	—	0.368	0.947
CrowdPose val	full	**0.7626**	0.6938	—	—	1.000	1.000
CrowdPose val	v=2	**0.4183**	0.3768	—	—	0.225	0.591
CrowdPose val	v=1	**0.5183**	0.4573	−0.2443	−0.2366	0.308	0.776
CrowdPose val	v=0	0	0	—	—	0.467	1.000
OCHuman test	full	**0.4775**	0.3379	—	—	1.000	1.000
OCHuman test	v=2	**0.4696**	0.3314	—	—	0.692	1.000
OCHuman test	v=1	**0.1819**	0.0765	−0.2955	−0.2614	0.143	0.736
OCHuman test	v=0	0	0	—	—	0.164	0.902

V. 结果

A. *RQ1*：全量 *mAP* 掩盖遮挡差异

表 III 给出两模型在三个数据集上的分层 mAP，以及层代表性证据 gt_frac 与 gt_person_frac；图 1 可视化分层结果。三点观察。

第一，Δ_{occ} **全部为负且量级可观**：COCO 上 −0.40 与 −0.41，CrowdPose −0.24，OCHuman −0.26 至 −0.30。在每一个受测组合中，全量 mAP 都高估了遮挡场景表现 24–41 个点。这一差距部分是固有困难：v=1 关键点对任何模型都更难，Δ_{occ} 把固有困难与掩盖混在了一起。能单独分离「掩盖」的模型级量是 $\Delta\Delta_{\text{occ}}=\Delta_{\text{occ}}(\text{YOLO})-\Delta_{\text{occ}}(\text{r5-3})$，它在三个数据集上均显著（COCO −0.013 [−0.018, −0.009]，CrowdPose +0.008 [+0.004, +0.011]，OCHuman +0.034 [+0.024, +0.043]；附录 A，表 A2）：两模型在「各自全量 mAP 高估遮挡场景的程度」上存在差异，而这一差异在聚合分数中完全不可见。

第二，**分层改变了模型比较的结论强度**。通用域 COCO 上，YOLO11s-pose 在全量与 v=2 层显著占优（$\Delta=+0.0104$，95% CI [0.0059,0.0155]），但 v=1 层未发现差异（$\Delta=-0.0028$，ns）——聚合分数上的显著优势几乎全部来自可见关键点。遮挡域数据集上，round5-3 三层全部显著占优（CrowdPose 全量 $\Delta=-0.0687$，OCHuman 全量 $\Delta=-0.1396$，95% CI 均不含 0），遮挡域训练的收益在 v=1 层同样显著（OCHuman v1 $\Delta=-0.1055$；CrowdPose 的 v2 层 AP 受全员召回分母低估，其跨层结论以 Δ_{occ} 为准，第 3.2 节）。不过与全量 mAP 的符号一致性仍是完美

表 IV
M2 关节角 RMSE（°，左右侧按实例合并）。粗体 = 显著占优（BOOTSTRAP CI 不含 0）；逐项比较的 CI 见附录 A（表 A3）。

数据集	模型	肘 v=2	肘 v=1	膝 v=2	膝 v=1
COCO val	round5-3	26.0	35.9	20.4	29.2
COCO val	YOLO11s-pose	25.4	35.6	21.0	31.2
CrowdPose val	round5-3	25.9	**31.6**	20.6	**25.9**
CrowdPose val	YOLO11s-pose	26.0	35.0	21.3	30.5
OCHuman test	round5-3	**35.6**	**45.7**	**24.3**	**32.0**
OCHuman test	YOLO11s-pose	39.6	57.7	28.3	39.7

表 V
膝内扣检出一致性（二值化 ϕ vs. GT）。粗体 = 更高值（ROUND5-3）；κ 及模型差的 BOOTSTRAP CI 见附录 A。

数据集	模型	τ_φ=10° κ	τ_φ=15° κ	τ_φ=17° κ	τ_φ=15° 灵敏度/特异度
COCO val	round5-3	0.724	**0.759**	0.773	0.790/0.950
COCO val	YOLO11s-pose	0.697	0.745	0.759	0.783/0.943
CrowdPose val	round5-3	0.711	**0.739**	0.731	0.785/0.937
CrowdPose val	YOLO11s-pose	0.666	0.669	0.665	0.722/0.926
OCHuman test	round5-3	0.601	**0.602**	0.603	0.646/0.926
OCHuman test	YOLO11s-pose	0.529	0.519	0.502	0.592/0.900

表 VI
M3 时序指标（总体，17 关键点平均）与平滑 AP 代价。匹配口径 AP 为在抖动指标所用同一批匹配轨迹帧上重算的 AP（原始值：ROUND5-3 0.1316 / YOLO11S-POSE 0.1408）；— = 原始参照，未施加平滑。粗体 AP 代价 = 位于零的 ±0.0002 内（零精度代价）。逐指标的域间差与模型间差 CI 见附录 A（表 A5）。

模型	口径	disp_mean	jitter_mean	jump_0.05	jump_0.10	AP 代价
round5-3	原始	0.0409	0.0521	0.2062	0.0726	—
round5-3	像素域平滑	0.0380	0.0509	0.1870	0.0634	+0.0001
round5-3	q 域平滑	0.0432	0.0528	0.2200	0.0807	−0.0013
YOLO11s-pose	原始	0.0430	0.0535	0.2153	0.0777	—
YOLO11s-pose	像素域平滑	0.0399	0.0523	0.1943	0.0679	+0.0002
YOLO11s-pose	q 域平滑	0.0462	0.0546	0.2336	0.0878	−0.0029

的（$\tau_s = 1.0$，第 5.4 节）：对受测的两个模型而言，分层改变的是模型差距的量级而非方向。我们把同样的分层扩展到 oracle 协议下的两个 Transformer 模型与两个 YOLO-oracle 模型（第 5.5 节），在该族内观察到同样的稳定性；统一 oracle 协议下的跨族重排名在第 5.5 节检验。

第三，v=0 **层恒为 0**（两模型、三数据集），验证协议预期：缺失关键点无法被估计；该层保留作完整性证据，不参与排名。

B. RQ2：角度误差与膝内扣检出一致性

表 IV 给出左右侧合并的肘/膝关节角 RMSE（按 v=2/v=1 分层）；图 2 展示逐关节误差分布（v=2 层）。三点观察。

第一，**角度误差被遮挡系统性放大**：每个模型-数据集组合中，v=1 层 RMSE 点估计均高于 v=2 层（肘 +5.7° 至 +18.1°，膝 +5.3° 至 +11.4°），层间差距在重度遮挡域（OCHuman）最大；逐组合的 v1−v2 层差配对 bootstrap CI 见附录 A（表 A13）。配套的 MAE 与 P95 统计量按模型、数据集、关节、层逐项列于附录 A（表 A15），复现同一规律（24 个模型-数据集-关节组合中，v=1 单元的 MAE 与 P95 全部高于其 v=2 对应单元，最大误差出现在 OCHuman 域）。这与 M1 的 Δ_{occ} 观察同向，两者互为佐证。

第二，**角度指标区分了全量 mAP 无法区分的信息**。通用域 COCO 上未发现两模型角度差异的证据（与 mAP 差 1 点一致）；但遮挡域上 round5-3 在 v=1 层每一项受测比较中都更准：CrowdPose 肘 31.6° vs. 35.0°、膝 25.9° vs. 30.5°（均显著）；OCHuman 肘 45.7° vs. 57.7°、膝 32.0° vs. 39.7°（全部显著）。注意 OCHuman 的 v=2 层角度差异同样显著，说明遮挡域训练的收益不限于被遮挡关键点本身。以上比较使用各模型自己的有效实例集；在两模型集合的交集上重算后，全部 24 个显著性判定不变（第 3.3 节）。

第三，**膝内扣检出一致性**（表 V）：round5-3 的 κ 在三个数据集上均高于 YOLO11s-pose（默认阈值 τ_φ=15° 下：COCO 0.759 vs. 0.745；CrowdPose 0.739 vs. 0.669；OCHuman 0.602 vs. 0.519），阈值敏感性分析（$\tau_\varphi \in \{10°, 17°\}$）下结论稳定。Bootstrap CI（附录 A，表 A4）确立 CrowdPose 与 OCHuman 的差距显著（$\Delta\kappa$ −0.069 [−0.098, −0.041] 与 −0.084 [−0.121, −0.046]），COCO 的差距方向一致但不显著（$\Delta\kappa$ −0.014 [−0.045, 0.016]）。两模型在 OCHuman 上的 κ 均偏低（< 0.61），提示重度遮挡下 ϕ 的测量噪声上升。

C. RQ3：无追踪推理的时序稳定性与平滑代价

PoseTrack18 val 上两模型各得到 704 / 728 条轨迹段（161 / 160 个视频，中位段长 31 帧）。段保留过滤相当严格：这些段覆盖标注帧的 53.4% / 53.1%，且 20.1% / 16.3% 的 GT 人员实例从未被匹配（第 3.4 节）。表 VI 给出 person-scale 归一化后的总体三指标与平滑 AP 代价；图 3 展示一条示例轨迹（round5-3 的最长左膝保留段，选作可视化示例；汇总统计以全部保留段为准）。

三点观察。第一，**两模型的原始时序稳定性未发现差异**：全部七个指标（位移/抖动均值与 P95、三档跳变率阈值）的 bootstrap CI 均包含 0。未发现遮挡域训练数据改变时序稳定性的证据——「未发现遮挡训练影响时序行为的

证据」本身即一个有信息量的结果，提示数据侧干预应与时序后处理分开考虑。

第二，**像素域 OneEuro 平滑以零匹配口径 AP 代价换取稳定性**：跳变率（$\tau_j = 0.05$）相对下降 9.3%（round5-3）与 9.7%（YOLO11s-pose）——更宽松的敏感性阈值 $\tau_j = 0.10$ 下降幅更大（12.7% / 12.6%，表 VI），并非默认阈值的偶然——帧间位移均值下降约 7%，AP 变化保持在 ±0.0002 内。这一收益不是默认参数的偶然：OneEuro 网格（min_cutoff × beta，第 3.4 节）的全部 12 个设置都把两模型每一项 M3 指标降到原始基线以下，且 $|\Delta\text{AP}| \le 0.0004$。第三，**q 域平滑适得其反**：三指标全面上升（jump_0.05 升至 0.2200/0.2336），AP 微降——GT 人框的逐帧尺度噪声在反归一化时被重新注入像素域（机制见 3.4 节）。这一对比说明：对无追踪逐帧输出做平滑时，滤波域的选择决定收益；协议因此固定像素域为主口径。

D. RQ4：指标间相关性

在（数据集 × 层）单元（$n = 6$）上，计算协议指标差（Δ = YOLO11s-pose − round5-3，RMSE 差经符号翻转使正值恒代表 YOLO11s-pose 更优）与全量 mAP 差的符号一致性 τ_s，仅统计全量 mAP 差互不相同的 12 对（3.5 节）：分层 mAP $\tau_s = 1.0$（12/12 对），肘角 RMSE $\tau_s = 1.0$（12/12），膝角 RMSE $\tau_s = 0.667$（10/12）；扩展到 24 个关节级单元，$\tau_s = 0.719$（C=165，D=27，共 192 对）。同一差值向量之间的 Spearman ρ：全量 Δ 与分层 Δ 之间 $\rho = 0.956$；全量 Δ 与肘角之间 $\rho = 0.956$；全量 Δ 与膝角之间 $\rho = 0.717$；肘角与膝角之间 $\rho = 0.771$（$n = 6$ 单元仅来自 3 个独立数据集，p 值仅作名义报告：$p = 0.003/0.003/0.109/0.072$，不用于推断）。两个相同的 $\rho = 0.956$ 并非转录错误：分层 mAP 与肘角误差的差值向量对六个单元的排序完全相同，且它们与全量 mAP 差的排序差异仅发生在同一数据集的两个层之间——该两层共享同一个全量 mAP 差（并列），Spearman 分子在两种情况下均不变。

两点解读（探索性；$n = 6$ 个单元仅来自 3 个独立数据集）。第一，**分层 mAP 的排名信息与全量 mAP 完全符号一致（$\tau_s = 1.0$）**；其协议价值不在重排名，而在量级诊断——Δ_{occ} 提供的「被掩盖多少」是标量 mAP 无法给出的。第二，**角度指标携带部分独立信息**：膝角 RMSE 与全量 AP 的差值排序并未重合，且在 COCO 上方向分歧（round5-3 膝角更准而全量 mAP 更低；表 IV）——角度协议捕获了 OKS 之外的差异维度（描述性证据，不作统计推断）。就协议精简而言：分层 mAP 与角度误差均不冗余，各自捕捉不同盲区。时序指标仅有一个数据集的单元，待更多数据检验。

表 VII

检测器无关 GT-BBOX ORACLE 协议下的 M1 分层 mAP^{50-95}(P)（PYCOCOTOOLS 2.0.11），四个模型。粗体 = VITPOSE-L 显著优于 VITPOSE-B（九个排名单元全部显著；CI 见附录 A 表 A6）。* = 标出的 YOLO-ORACLE 模型显著优于另一个 YOLO-ORACLE 模型（统一协议下的族内训练数据效应；CI 见附录 A 表 A8）。Δ_{occ}（v1 层 − 全量）：VITPOSE-B 为 −0.4666/−0.2420/−0.3470，VITPOSE-L 为 −0.4698/−0.2381/−0.3448，ROUND5-3-ORACLE 为 −0.3310/−0.2068/−0.2276，YOLO11S-ORACLE 为 −0.3440/−0.1947/−0.2308（COCO/CROWDPOSE/OCHUMAN）。† 检测式运行，协议不同；仅作通向表 III–VI 的桥梁。

数据集	层	ViTPose-B	ViTPose-L	r5-3-oracle	YOLO11s-oracle	r5-3†
COCO val	full	0.7676	**0.7988**	0.4250	**0.4411***	0.5712
COCO val	v=2	0.7612	**0.7903**	0.4188	**0.4347***	0.5637
COCO val	v=1	0.3010	**0.3290**	0.0940	0.0971	0.1747
COCO val	v=0	0	0	0	0	0
CrowdPose val	full	0.8360	**0.8653**	**0.5591***	0.5148	0.7626
CrowdPose val	v=2	0.4905	**0.5042**	**0.2783***	0.2555	0.4183
CrowdPose val	v=1	0.5940	**0.6272**	**0.3523***	0.3201	0.5183
CrowdPose val	v=0	0	0	0	0	0
OCHuman test	full	0.5514	**0.6083**	**0.3546***	0.3044	0.4775
OCHuman test	v=2	0.5388	**0.5966**	**0.3403***	0.2901	0.4696
OCHuman test	v=1	0.2044	**0.2636**	**0.1270***	0.0736	0.1819
OCHuman test	v=0	0	0	0	0	0

E. RQ5：跨架构的盲区与排名稳定性

为检验三个盲区是否为单阶段检测式 YOLO 模型对的特有现象，我们在检测器无关的 GT-bbox oracle 协议（第 4 节）下评测了两个不同容量的自顶向下 Transformer 模型——ViTPose-B 与 ViTPose-L。为使跨架构比较成为同协议的统计检验，两个 YOLO 模型也在 oracle 协议下额外评测（GT 人框裁剪、letterbox 640×640、不翻转；单阶段模型由裁剪引起的尺度偏移在相关处注明）。五个 oracle 运行均为每个 GT 标注输出一个预测，因此本节的任何比较都不含检测器误差；检测式 round5-3 列在表 VII 与表 VIII 中保留，作为通向 RQ1–RQ4 数字的桥梁。

四点观察。第一，**三个盲区在更强的 Transformer 模型上依然存在——且部分加深，YOLO 模型对在同一协议下同样如此**。oracle 协议下每个组合的 Δ_{occ} 均为负：Transformer 模型对 −0.24 至 −0.47，YOLO-oracle 模型对 −0.19 至 −0.34，Transformer 的量级与检测式模型对（−0.24 至 −0.41）相当或更大；COCO 上 ViTPose oracle 的 Δ_{occ}（−0.47）甚至超过检测式的 −0.40。更强的架构或更大的容量买不来更小的盲区：两种协议下，全量 mAP 都把遮挡场景表现高估了 19–47 个点。

表 VIII

ORACLE 协议下的 M2 关节角 RMSE（°，左右侧按实例合并），四个模型。两个 VITPOSE 模型间的显著性在逐关节层面判定（附录 A 表 A7）：24 项比较中 5 项显著、全部利于 VITPOSE-L；粗体标出两项逐关节比较均显著的合并单元。YOLO-ORACLE 族内显著性亦为逐关节（附录 A 表 A11）：COCO 无显著项，CROWDPOSE 一项（左肘 v=1，−3.0°），OCHUMAN 三项（左肘 v=1 −9.2°、右肘 v=2 −4.1°、右肘 v=1 −8.2°），全部利于 ROUND5-3-ORACLE。† 检测式运行；仅作通向表 IV 的桥梁。

数据集	模型	肘 v=2	肘 v=1	膝 v=2	膝 v=1
COCO val	ViTPose-B	17.8	31.0	14.2	33.7
COCO val	ViTPose-L	**14.9**	28.0	12.6	28.5
COCO val	round5-3-oracle	27.0	41.8	23.6	39.1
COCO val	YOLO11s-oracle	28.0	40.2	24.5	38.3
COCO val	round5-3†	26.0	35.9	20.4	29.2
CrowdPose val	ViTPose-B	14.9	30.7	13.1	28.5
CrowdPose val	ViTPose-L	13.6	28.0	11.8	26.8
CrowdPose val	round5-3-oracle	27.9	33.1	24.6	32.4
CrowdPose val	YOLO11s-oracle	28.8	35.6	27.1	35.2
CrowdPose val	round5-3†	25.9	31.6	20.6	25.9
OCHuman test	ViTPose-B	36.5	55.3	21.6	36.9
OCHuman test	ViTPose-L	33.7	51.8	19.2	33.0
OCHuman test	round5-3-oracle	37.7	49.2	24.5	38.6
OCHuman test	YOLO11s-oracle	40.6	57.9	26.9	40.5
OCHuman test	round5-3†	35.6	45.7	24.3	32.0

表 IX

ORACLE 协议下的 M3 时序指标（POSETRACK18 VAL；保留轨迹段：VITPOSE-B/L 为 868 / 885，ROUND5-3-ORACLE / YOLO11S-ORACLE 为 709 / 651，覆盖 170 个视频）。匹配口径 AP：0.5248 / 0.5548（VITPOSE-B/L），0.3301 / 0.3085（ROUND5-3-ORACLE / YOLO11S-ORACLE；ORACLE 值，与表 VI 的检测式值不可比）。AP 代价 = 平滑后匹配口径 AP − 原始。YOLO-ORACLE 的平滑总结在正文（第 5.5 节）。† 检测式运行（表 VI）；仅作桥梁。

模型	口径	disp_mean	jitter_mean	jump_0.05	jump_0.10	AP 代价
ViTPose-B	原始	0.0389	0.0526	0.1648	0.0597	—
ViTPose-B	像素域平滑	0.0370	0.0517	0.1555	0.0557	−0.0001
ViTPose-B	q 域平滑	0.0755	0.0549	0.2004	0.0776	−0.0146
ViTPose-L	原始	0.0385	0.0538	0.1599	0.0563	—
ViTPose-L	像素域平滑	0.0368	0.0530	0.1514	0.0529	−0.0003
ViTPose-L	q 域平滑	0.0742	0.0560	0.1966	0.0751	−0.0185
round5-3-oracle	原始	0.0441	0.0534	0.2229	0.0773	—
YOLO11s-oracle	原始	0.0463	0.0542	0.2322	0.0828	—

第二，**oracle 协议把时序抖动分解为检测器、训练数据与跨族三个分量**。移除检测器并不能消除任何一个架构族的抖动：Transformer 模型对在无检测器的情况下跳变率仍为 0.165（B）/ 0.160（L），YOLO 模型对按 oracle 协议重跑后跳变率为 0.223/0.232——不低于其检测式的 0.206/0.215（oracle 运行的预处理与匹配段总体不同，这最后一项比较是提示性的，并非受控分解）。残余高频抖动因此在无检测器参与时依然存在；它究竟是姿态头内生还是残余预处理差异所致，在当前 oracle 设计下无法分离。统一 oracle 协议下，全部四项跨族比较在 disp_mean、jump_0.05 与 jump_0.10 上均显著，disp_p95 为四分之三显著（ViTPose-B − round5-3-oracle 的 disp_p95 CI [−0.0275, +0.0006] 含 0；如 ViTPose-B − round5-3-oracle 的 jump_0.05 为 −0.058 [−0.080, −0.036]；附录 A 表 A10）：Transformer 族显著更时序稳定——这是跨族差异，其中架构与预处理、输入分辨率、翻转测试相互混杂。YOLO-oracle 模型对在所有 M3 指标上均无差异（全部七个 CI 含 0）：训练数据差异不改变时序稳定性，跨族差距才会。jitter_mean 在全部六个运行、两种协议下几乎恒定（0.0521–0.0542），提示中值滤波残差度量的是逐帧热图推断的稳定属性，而非模型特有属性。平滑域结论在 YOLO-oracle 模型对上同样复现：像素域平滑把跳变率降低 10.7%（round5-3-oracle）而匹配口径 AP 仅 +0.0009，q 域平滑反而上升 5.0% 并付出 0.0068 AP。像素域主口径因此跨架构成立，q 域失效机制与架构无关。

第三，**两个族内的排名都稳定**。ViTPose-L 在全部九个 M1 排名单元上显著优于 ViTPose-B（CI 见附录 A 表 A6；如 COCO 全量 +0.0312 [+0.0247, +0.0329]），M2 方向性占优（24 项逐关节比较中 5 项显著、全部利于 ViTPose-L，集中于 v=2 层）。YOLO 族内，oracle 协议在每个数据集上都保持了检测式的排名：COCO 全量与 v=2 层 YOLO11s-oracle 显著占优（round5-3-oracle $\Delta = -0.0161$ [−0.0220, −0.0099]），CrowdPose 与 OCHuman 三层全部由 round5-3-oracle 显著占优（全量 +0.0442 [+0.0361, +0.0527] 与 +0.0501 [+0.0383, +0.0633]；表 A8）。域差距在 oracle 下缩小——OCHuman 全量检测式 +0.1396 对比 oracle +0.0501——说明 round5-3 的检测式优势有一部分是检测器带来的，但训练数据效应本身在移除检测器后依然存在。

第四，**协议把训练数据效应与模型容量效应分离开来，且现已具备统计性**。统一协议下 OCHuman 的 v=1 层上，遮挡域训练的小模型 round5-3-oracle 取得左肘 47.4° / 左膝 37.1°，对比 ViTPose-B 的 54.7° / 36.7°（单侧 RMSE，与表 A12 的单侧 CI 口径一致）：round5-3-oracle 在遮挡肘部层显著比 ViTPose-B 更准（左肘，ViTPose-B − round5-3-oracle $\Delta = +7.4°$ [+2.4, +12.5]；表 A12），且 ViTPose-L 在任何 v=1 关节上都未显著超越它（左肘 ViTPose-L 为 +4.6° [−0.4, +9.5]，ns；膝部 ns）——尽管 ViTPose-L 的全量 mAP 领先 +0.2538（0.6083 vs. 0.3546）。没有遮挡域训练数据的容量优势不会转化为遮挡层角度精度；这一分离在两种协议的全量 mAP 中均不可见，正是协议新增的信息。

综上，同协议比较表明：（i）三个盲区在一个统一协议下跨架构族持续存在；（ii）族内训练数据效应在移除检测器后以压缩的量级存活；（iii）时序稳定性因两个架构族而异、不因训练数据而异；（iv）遮挡域训练的小模型保持着对 ViTPose-B 的显著遮挡肘角优势，连 ViTPose-L 也未能显著逆转。

VI. 讨论

三盲区的量级据我们所知首次在同一协议下被量化。四个数据集、两个模型的一致观察是：全量 mAP 对遮挡场景的高估（Δ_{occ} -0.24 至 -0.41）、遮挡对角度误差的放大（v=1 层肘角 RMSE 最高 $+18.1°$）、以及无追踪逐帧输出的高频抖动（PoseTrack18 val 保留段子总体上、默认阈值 $\tau_j = 0.05$ 下两模型跳变率 ≈ 0.21，可被像素域平滑以零匹配口径 AP 代价降低约 10%）。这些数字共同说明：仅由 OKS-mAP 驱动的模型选择会误读两个受测模型之间差距的构成——COCO 上 YOLO11s-pose 的显著聚合优势几乎全部来自可见关键点、并不延伸到遮挡层，而两模型在遮挡掩盖程度上的差异（$\Delta\Delta_{\text{occ}}$，第 5.1 节）在三个数据集上均显著——这些都是聚合分数中不可见的差异。这些盲区的量级并非单一架构特有：oracle 协议下 Transformer 模型对以更大的遮挡掩盖复现同一模式，YOLO 模型对在同一协议下以压缩的量级再次复现（第 5.5 节）；oracle 分解显示残余时序抖动在移除检测器后依然存在，并显示 Transformer 族的跳变率显著低于 YOLO 族。

角度协议与效度研究的边界。本文的角度指标以 GT 推导角度为参照，回答「哪个模型的关节角更接近标注真值」——一种模型比较工具。它不验证「估测角度是否等于临床金标准」，后者是 markerless 效度文献 [4]–[6] 的任务，需要标记点或专家标注。两者互补：效度研究证明某个模型在特定场景可信，本协议则让任何新模型在标准数据集上获得角度维度的可比较分数。同样，膝内扣检出一致性（默认阈值 τ_φ=15° 下 κ 最高 0.76）只断言「与 GT 标注一致」，不断言临床意义。

时序指标的工程含义。M3 的发现直接指导系统设计：其一，数据侧干预（遮挡训练）不改变时序稳定性，时序质量必须单独处理；其二，平滑域选择决定收益——归一化域滤波看似理论正确，实际因 GT 框尺度噪声重注入而失效；其三，oracle 分解（第 5.5 节）显示残余抖动在移除检测器后依然存在——改进检测并非抓手；应走后处理或姿态头层面的改进，而姿态头内生与预处理贡献的分离需预处理一致的对照实验确认。协议固定像素域主口径，并建议任何时序平滑方法报告「平滑前后抖动 + AP 代价」的联合表。

局限。（1）基准在两种协议下覆盖两个架构族：YOLO 族内模型对为检测式，ViTPose 族内模型对使用检测器无关的 oracle 协议，而全部跨族比较均在统一 oracle 协议下进行。YOLO-oracle 变体使用 GT 人框裁剪加 letterbox 而非 Transformer 的 UDP 预处理，且两者在输入分辨率（640×640 vs. 256×192）与翻转测试的使用（无 vs. 有）上亦有差异。跨族比较因此明确存在混杂：预处理、分辨率与翻转测试差异未与架构差异分离，任何跨族差距都应解读为联合效应而非纯架构效应（第 5.5 节采用此表述）。将基准扩展到其他架构（如 RTMPose、DWPose）留待后续工作，协议价值在于口径与工具；（2）CrowdPose 官方标注的可见性聚类（可见点几乎全为 v=2）叠加全员召回分母使其 v2 层 AP 被系统性低估，该数据集上跨层比较使用 Δ_{occ}；（3）角度为 2D 图像平面角，受视角影响，不是 3D 关节角或临床角度；（4）M3 仅覆盖一个数据集，且其保留段子总体只覆盖约 53% 的标注帧，时序结论的普适性待扩展；（5）RQ4 相关分析的单元数小（$n = 6$ 个单元仅来自 3 个独立数据集），属探索性；（6）COCO 的 v=1 层仅占关键点 7.8%，其 v=1 层估计方差较大（CI 更宽）；（7）M2 的比较使用各模型自己的有效实例集；在共享交集上重算后全部显著性判定不变，但覆盖差异明显的模型应改用交集口径。每张表均注明评估口径：M1/M2 数字遵循 pycocotools 2.0.11，而 PoseTrack 的官方指标数字（第 4 节）因无官方 pycoco 对照而以 ultralytics 内部评估器口径报告。

VII. 结论

本文提出并执行了一个面向遮挡、关节角度与时序稳定性的二维人体姿态估计统一补充评估协议，配套开源 harness 与可复现契约。两个架构族、四个模型、四个公开数据集上的基准结果显示：在每一个受测的模型-数据集组合中，全量 OKS-mAP 都掩盖了遮挡特定的精度差异（Δ_{occ} 达 -0.47）；角度误差协议捕获了 OKS 之外的部分独立信息；在 PoseTrack18 val 的已匹配保留段子总体上，像素域平滑能以零匹配口径 AP 代价降低时序抖动；检测器无关的 oracle 协议进一步显示残余抖动在移除检测器后依然存在（并非检测器内生）——三个盲区在一个统一 oracle 协议下跨架构持续存在，且跨族排名、训练数据与时序稳定性效应可在显著性层面分离。协议定位为 OKS-mAP 的补充而非替代：它不改变主流排名的底层口径，而是为模型选择与系统设计增加三个此前不可见的诊断维度。代码与全部原始预测已开源。

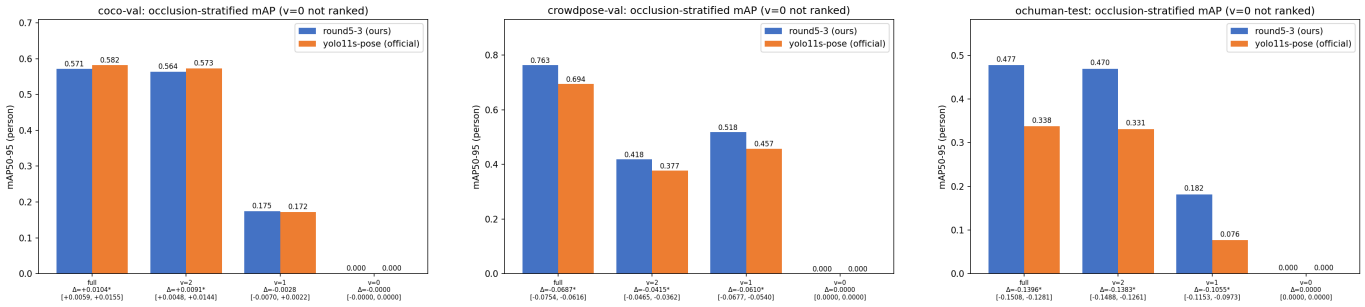


图 1. M1 遮挡分层 mAP^{50-95}(P)（分数据集）：(a) COCO val2017，(b) CrowdPose val，(c) OCHuman test。柱状图展示 round5-3 与 YOLO11s-pose 的全量与逐层 mAP；每组下方标注两模型差值 Δ 及其 95% bootstrap CI（∗ = CI 不含 0）。v=0 层为完整性展示，不参与排名。

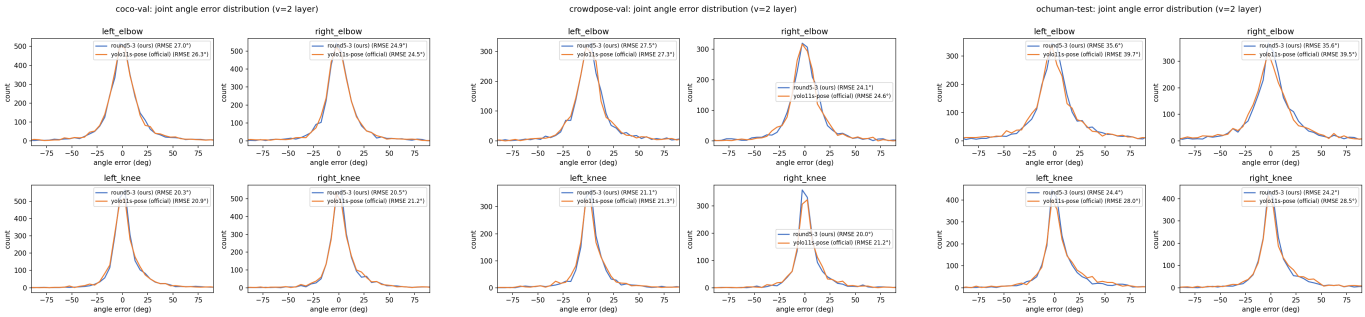


图 2. M2 关节角度误差分布（v=2 层，分数据集）：(a) COCO val2017，(b) CrowdPose val，(c) OCHuman test。每幅子图展示两模型逐关节误差直方图（$\theta_{\mathrm{pred}} - \theta_{\mathrm{gt}}$），图例含 RMSE。分布集中于 0° 附近；遮挡域数据集对两模型的区分更清晰（表 IV）。

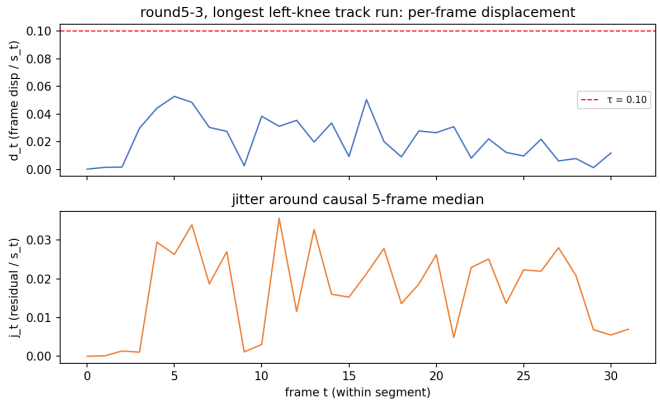


图 3. M3 时序抖动示例（PoseTrack18 val 一条示例轨迹——round5-3 的最长左膝保留段；展示用途而非汇总统计量）：（上）按人框尺度归一化的逐帧位移 d_t，含敏感性跳变阈值 $\tau_j = 0.10$；（下）因果 5 帧中值滤波周围的残差抖动 j_t。

附录 A
Bootstrap 置信区间

所有区间均为逐比较、未做多重校正的 95% 百分位 bootstrap CI，10,000 次重采样，seed 42；显著性仅作辅助，核心结论以三数据集方向一致性与效应量支撑。核心比较族的 Benjamini–Hochberg FDR 校正敏感性分析见表 A14。重采样单元：M1 与 M2 为图像（各指标在模型比较前先在该单元上聚合），M3 为轨迹段。配对比较在两量之间共享同一重采样索引；模型间比较对两模型单元独立重采样。符号约定：Δ = YOLO11s-pose − round5-3，故 $\Delta < 0$ 对 AP 与 κ 表示 round5-3 占优，对 RMSE 表示 YOLO11s-pose 占优；oracle 协议比较（表 A6–A7）Δ = ViTPose-L − ViTPose-B，故 $\Delta > 0$ 对 AP 表示 ViTPose-L 占优，$\Delta < 0$ 对 RMSE 表示 ViTPose-L 占优；表 A8 中 Δ = round5-3-oracle − YOLO11s-oracle，故 $\Delta > 0$ 对 AP 表示 round5-3-oracle 占优，$\Delta < 0$ 对 RMSE 表示其占优；表 A9 中 Δ =（Transformer 模型）−（YOLO-oracle 模型）按列头标示，故 $\Delta > 0$ 对 AP 表示前者占优，$\Delta < 0$ 对 RMSE 表示前者占优；表 A10 中 Δ =（Transformer 模型）−（YOLO-oracle 模型）按行标示，故 $\Delta < 0$ 表示 Transformer 占优（抖动更低）；表 A11–A12 中 Δ =（前一名模型）−（后一名模型）按表头标示，故 $\Delta < 0$ 对 RMSE 表示前一名模型占优；表 A13 中 Δ = 同模型内 RMSE(v=1)−RMSE(v=2)，故 $\Delta > 0$ 表示遮挡层误差更高；表 A14 中 Δ = round5-3 − YOLO11s-pose（族内一致），故 $\Delta > 0$ 对 AP 表示 round5-3 占优、对 RMSE 与抖动指标表示 YOLO11s-pose 占优。表 A15 仅列 MAE/P95

表 A1

M1 分层 AP 对比及 bootstrap 置信区间。Δ = YOLO11s-pose − round5-3；* CI 不含 0。

数据集	层	AP r5-3	AP YOLO	Δ AP [95% CI]
COCO val	full	0.5712	0.5816	0.0104 [0.0059, 0.0155]*
COCO val	v=2	0.5637	0.5728	0.0091 [0.0048, 0.0144]*
COCO val	v=1	0.1747	0.1719	-0.0028 [-0.0070, 0.0022]
COCO val	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]
CrowdPose val	full	0.7626	0.6938	-0.0687 [-0.0754, -0.0616]*
CrowdPose val	v=2	0.4183	0.3768	-0.0415 [-0.0465, -0.0362]*
CrowdPose val	v=1	0.5183	0.4573	-0.0610 [-0.0677, -0.0540]*
CrowdPose val	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]
OCHuman test	full	0.4775	0.3379	-0.1396 [-0.1508, -0.1281]*
OCHuman test	v=2	0.4696	0.3314	-0.1383 [-0.1488, -0.1261]*
OCHuman test	v=1	0.1819	0.0765	-0.1055 [-0.1153, -0.0973]*
OCHuman test	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]

单位：图像（两模型共享同一图像域；配对重采样）。10,000 次重采样，seed 42，95% 百分位 CI。

表 A2

M1 Δ_{occ}（mAP(v=1) − mAP(full)）逐模型值及模型差，附 bootstrap CI。

数据集	Δ_{occ} r5-3 [95% CI]	Δ_{occ} YOLO [95% CI]	$\Delta\Delta_{occ}$ [95% CI]
COCO val	-0.3965 [-0.4075, -0.3858]	-0.4097 [-0.4205, -0.3989]	-0.0132 [-0.0177, -0.0086]*
CrowdPose val	-0.2443 [-0.2565, -0.2322]	-0.2366 [-0.2488, -0.2246]	0.0077 [0.0041, 0.0110]*
OCHuman test	-0.2955 [-0.3080, -0.2842]	-0.2614 [-0.2729, -0.2527]	0.0341 [0.0237, 0.0429]*

单位：图像（配对）；$\Delta\Delta_{occ}$ 在配对重采样上逐元素计算。10,000 次重采样，seed 42，95% 百分位 CI。

表 A3

M2 关节角 RMSE（°，左右侧按实例合并）及 bootstrap CI。Δ = YOLO11s-pose − round5-3（负值 = YOLO 误差更低）；* CI 不含 0。

数据集	关节	层	RMSE r5-3	RMSE YOLO	Δ RMSE [95% CI]	n_{img}
COCO val	左肘	v=2	27.0	26.3	-0.7 [-3.1, 1.7]	1720 / 1727
COCO val	左肘	v=1	33.5	36.6	3.1 [-4.8, 10.9]	248 / 247
COCO val	右肘	v=2	24.9	24.5	-0.5 [-2.8, 1.9]	1732 / 1730
COCO val	右肘	v=1	37.7	34.8	-2.9 [-9.1, 3.5]	290 / 292
COCO val	左膝	v=2	20.3	20.9	0.6 [-2.0, 3.1]	1320 / 1325
COCO val	左膝	v=1	30.8	32.2	1.4 [-8.9, 11.3]	180 / 182
COCO val	右膝	v=2	20.5	21.2	0.7 [-1.6, 3.2]	1302 / 1306
COCO val	右膝	v=1	27.7	30.3	2.6 [-6.9, 12.3]	202 / 205
CrowdPose val	左肘	v=2	27.5	27.3	-0.2 [-2.9, 2.6]	790 / 793
CrowdPose val	左肘	v=1	31.3	35.0	3.7 [1.4, 6.1]*	1319 / 1321
CrowdPose val	右肘	v=2	24.1	24.6	0.6 [-2.0, 3.2]	810 / 811
CrowdPose val	右肘	v=1	31.9	35.0	3.1 [0.7, 5.5]*	1343 / 1338
CrowdPose val	左膝	v=2	21.1	21.3	0.2 [-3.3, 3.7]	575 / 575
CrowdPose val	左膝	v=1	25.7	30.5	4.9 [2.1, 7.7]*	1085 / 1081
CrowdPose val	右膝	v=2	20.0	21.2	1.2 [-2.0, 4.4]	570 / 571
CrowdPose val	右膝	v=1	26.2	30.5	4.4 [1.4, 7.2]*	1104 / 1096
OCHuman test	左肘	v=2	35.6	39.7	4.2 [1.7, 6.6]*	1931 / 1951
OCHuman test	左肘	v=1	45.4	56.2	10.8 [7.0, 14.7]*	860 / 871
OCHuman test	右肘	v=2	35.6	39.5	3.9 [1.4, 6.4]*	1935 / 1947
OCHuman test	右肘	v=1	46.0	59.2	13.2 [9.2, 17.3]*	822 / 831
OCHuman test	左膝	v=2	24.4	28.0	3.6 [1.1, 6.2]*	1507 / 1514
OCHuman test	左膝	v=1	30.7	39.5	8.8 [3.7, 14.0]*	498 / 499
OCHuman test	右膝	v=2	24.2	28.5	4.3 [1.8, 6.9]*	1499 / 1503
OCHuman test	右膝	v=1	33.3	39.9	6.6 [0.9, 12.4]*	525 / 534

单位：图像，逐模型独立重采样（各模型的图像集只含该关节、该层至少有一个有效实例的图像）；末列 n_{img}：round5-3 / YOLO11s-pose。10,000 次重采样，seed 42，95% 百分位 CI。

表 A4

膝内扣检出一致性（κ、灵敏度、特异度）及 bootstrap CI。Δ = YOLO11s-pose − round5-3；* CI 不含 0。

数据集	τ_φ	κ r5-3 [95% CI]	κ YOLO [95% CI]	模型差 [95% CI]		
				Δκ	Δ 灵敏度	Δ 特异度
COCO val	10°	0.724 [0.702, 0.745]	0.697 [0.673, 0.719]	-0.027 [-0.058, 0.003]	-0.015 [-0.043, 0.014]	-0.012 [-0.029, 0.005]
COCO val	15°	0.759 [0.738, 0.780]	0.745 [0.723, 0.767]	-0.014 [-0.045, 0.016]	-0.006 [-0.039, 0.026]	-0.006 [-0.019, 0.006]
COCO val	17°	0.773 [0.751, 0.794]	0.759 [0.737, 0.780]	-0.014 [-0.045, 0.017]	-0.006 [-0.039, 0.027]	-0.006 [-0.017, 0.006]
CrowdPose val	10°	0.711 [0.692, 0.729]	0.666 [0.646, 0.685]	-0.045 [-0.073, -0.018]*	-0.029 [-0.052, -0.004]	-0.017 [-0.032, -0.001]
CrowdPose val	15°	0.739 [0.719, 0.757]	0.669 [0.648, 0.690]	-0.069 [-0.098, -0.041]*	-0.063 [-0.091, -0.034]	-0.011 [-0.024, 0.002]
CrowdPose val	17°	0.731 [0.711, 0.750]	0.665 [0.643, 0.687]	-0.067 [-0.096, -0.037]*	-0.067 [-0.097, -0.037]	-0.007 [-0.019, 0.005]
OCHuman test	10°	0.601 [0.577, 0.625]	0.528 [0.502, 0.554]	-0.073 [-0.108, -0.037]*	-0.041 [-0.072, -0.010]	-0.030 [-0.051, -0.010]
OCHuman test	15°	0.602 [0.576, 0.627]	0.519 [0.490, 0.546]	-0.084 [-0.121, -0.046]*	-0.054 [-0.090, -0.017]	-0.026 [-0.041, -0.011]
OCHuman test	17°	0.603 [0.576, 0.628]	0.501 [0.473, 0.530]	-0.101 [-0.140, -0.062]*	-0.071 [-0.110, -0.032]	-0.026 [-0.039, -0.011]

单位：图像（二值化 ϕ 实例按图像汇总），逐模型独立重采样。10,000 次重采样，seed 42，95% 百分位 CI。

原始点估计，不带区间。* 标记不含 0 的区间。固定比较清单的每一项均列出，无挑选。

参考文献

[1] T.-Y. Lin *et al.*, "Microsoft COCO: Common objects in context," in *Proc. ECCV*, 2014.

[2] S.-H. Zhang *et al.*, "Pose2Seg: Detection free human instance segmentation," in *Proc. CVPR*, 2019; arXiv:1803.10683, 2018.

[3] M. Andriluka *et al.*, "PoseTrack: A benchmark for human pose estimation and tracking," in *Proc. CVPR*, 2018; arXiv:1712.09184, 2017.

[4] J. Turner, J. Clark, and N. Keshtmand, "Markerless pose estimation for resistance training technique assessment," arXiv:2608.24384, 2026.

[5] Panconi *et al.*, "Deep-learning-based markerless pose estimation systems in gait analysis," arXiv:2407.10590, 2024.

[6] Pemasiri *et al.*, "Biomechanically accurate gait analysis," arXiv:2603.02499, 2026.

[7] J. Li *et al.*, "CrowdPose: Efficient crowded scenes pose estimation and a new benchmark," arXiv:1812.00324, 2018.

[8] A. Ghafoor and A. Mahmood, "Quantification of occlusion handling capability of a 3D human pose estimation framework," *IEEE Trans. Multimedia*, arXiv:2203.04113, 2022.

[9] I. Sárándi, T. Linder, K. O. Arras, and B. Leibe, "How robust is 3D human pose estimation to occlusion?" in *Proc. IROS Workshop on Robotic Co-workers 4.0*, 2018; arXiv:1808.09316, 2018.

[10] Y. Garg, S. Bachu, A. Dutta, R. Lal, S. Bose, C.-K. Ta, M. S. Asif, and A. Roy-Chowdhury, "VOccl3D: A video benchmark dataset for 3D human pose and shape estimation under real occlusions," arXiv:2508.06757, 2025.

[11] I. L. A. Mendonça, F. M. do Nascimento Filho, G. Badicu, D. P. de Vasconcelos, T. B. Lima, V. Calmon, J. P. de Farias Neto, G. K. Jakubiak, L. Y. S. Maciel, F. J. Aidar, and W. Monteiro da Silva Júnior, "Analysis of ankle mobility and dynamic valgus knee in runners with and without patellofemoral pain syndrome," *Health Science Reports*, vol. 9, e72051, 2026.

[12] C. Lei *et al.*, "Deep video prior for video consistency and propagation," *IEEE Trans. Pattern Anal. Mach. Intell.*, arXiv:2201.11632, 2022.

[13] G. Casiez, N. Roussel, and D. Vogel, "1€ Filter: A simple speed-based low-pass filter for noisy input in interactive systems," in *Proc. CHI*,

表 A5

M3 时序指标：各域点值、模型内域差（PX−RAW、Q−RAW）及 RAW 域上的模型间差，均附 BOOTSTRAP CI。Δ（模型）= YOLO11S-POSE − ROUND5-3；* CI 不含 0。

指标	raw r5-3	raw YOLO	Δ raw	px−raw r5-3	px−raw YOLO	q−raw r5-3	q−raw YOLO
$\bar{d}$	0.0409	0.0430	0.0022 [-0.0019, 0.0062]	-0.0029 [-0.0031, -0.0027]*	-0.0031 [-0.0033, -0.0030]*	0.0023 [0.0015, 0.0031]*	0.0031 [0.0022, 0.0041]*
$\bar{f}$	0.0521	0.0535	0.0014 [-0.0047, 0.0075]	-0.0012 [-0.0013, -0.0011]*	-0.0013 [-0.0013, -0.0012]*	0.0007 [0.0003, 0.0011]*	0.0010 [0.0006, 0.0015]*
d_{95}	0.1194	0.1246	0.0051 [-0.0081, 0.0183]	-0.0086 [-0.0093, -0.0076]*	-0.0088 [-0.0096, -0.0080]*	0.0079 [0.0050, 0.0111]*	0.0103 [0.0070, 0.0140]*
f_{95}	0.1669	0.1719	0.0050 [-0.0177, 0.0275]	-0.0038 [-0.0046, -0.0032]*	-0.0044 [-0.0049, -0.0035]*	0.0031 [0.0008, 0.0056]*	0.0043 [0.0021, 0.0073]*
$\text{jump}_{0.05}$	0.2062	0.2153	0.0091 [-0.0145, 0.0326]	-0.0191 [-0.0206, -0.0177]*	-0.0210 [-0.0224, -0.0195]*	0.0139 [0.0091, 0.0188]*	0.0183 [0.0132, 0.0235]*
$\text{jump}_{0.10}$	0.0726	0.0777	0.0051 [-0.0086, 0.0190]	-0.0092 [-0.0102, -0.0082]*	-0.0098 [-0.0108, -0.0090]*	0.0081 [0.0052, 0.0113]*	0.0100 [0.0067, 0.0135]*
$\text{jump}_{0.20}$	0.0152	0.0184	0.0032 [-0.0015, 0.0079]	-0.0025 [-0.0030, -0.0021]*	-0.0030 [-0.0035, -0.0026]*	0.0024 [0.0011, 0.0038]*	0.0030 [0.0014, 0.0047]*

单位：轨迹段。域差为配对设计（跨域同一重采样索引，轨迹段由 raw 匹配固定）；模型间差对两模型轨迹段独立重采样。10,000 次重采样，seed 42（YOLO11s-pose 模型间分布为 1042），95% 百分位 CI。

表 A6

检测器无关 ORACLE 协议下的 M1 逐层 AP 及 BOOTSTRAP CI。Δ = VITPOSE-L − VITPOSE-B；* CI 不含 0。

数据集	层	AP ViTPose-B	AP ViTPose-L	Δ AP [95% CI]
COCO val	full	0.7676	0.7988	0.0312 [0.0247, 0.0329]*
COCO val	v=2	0.7612	0.7903	0.0291 [0.0246, 0.0329]*
COCO val	v=1	0.3010	0.3290	0.0280 [0.0241, 0.0333]*
COCO val	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]
CrowdPose val	full	0.8360	0.8653	0.0293 [0.0238, 0.0320]*
CrowdPose val	v=2	0.4905	0.5042	0.0137 [0.0113, 0.0179]*
CrowdPose val	v=1	0.5940	0.6272	0.0332 [0.0294, 0.0382]*
CrowdPose val	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]
OCHuman test	full	0.5514	0.6083	0.0570 [0.0477, 0.0658]*
OCHuman test	v=2	0.5388	0.5966	0.0578 [0.0493, 0.0677]*
OCHuman test	v=1	0.2044	0.2636	0.0592 [0.0511, 0.0678]*
OCHuman test	v=0	0.0000	0.0000	0.0000 [0.0000, 0.0000]

单位：图像（配对；oracle 协议下两模型共享同一图像域）。10,000 次重采样，seed 42，95% 百分位 CI。

表 A7

检测器无关 ORACLE 协议下的 M2 关节角 RMSE（°，逐侧）及 BOOTSTRAP CI。Δ = VITPOSE-L − VITPOSE-B（负值 = VITPOSE-L 误差更低）；* CI 不含 0。

数据集	关节	层	RMSE ViTPose-B	RMSE ViTPose-L	Δ RMSE [95% CI]	n_{img}
COCO val	左肘	v=2	18.3	15.5	-2.7 [-5.1, -0.4]*	1747 / 1750
COCO val	左肘	v=1	29.0	27.8	-1.2 [-9.2, 6.7]	261 / 262
COCO val	右肘	v=2	17.3	14.3	-3.0 [-5.5, -0.5]*	1757 / 1756
COCO val	右肘	v=1	32.6	28.2	-4.4 [-12.4, 3.5]	307 / 312
COCO val	左膝	v=2	13.9	12.9	-0.9 [-3.3, 1.5]	1347 / 1349
COCO val	左膝	v=1	33.4	25.2	-8.2 [-17.4, 1.1]	187 / 188
COCO val	右膝	v=2	14.5	12.3	-2.1 [-4.3, 0.1]	1328 / 1329
COCO val	右膝	v=1	33.9	31.1	-2.8 [-13.2, 7.6]	212 / 214
CrowdPose val	左肘	v=2	14.9	14.1	-0.8 [-3.0, 1.5]	795 / 793
CrowdPose val	左肘	v=1	31.5	29.5	-2.0 [-4.6, 0.6]	1327 / 1327
CrowdPose val	右肘	v=2	14.8	13.0	-1.8 [-4.0, 0.3]	811 / 811
CrowdPose val	右肘	v=1	29.8	26.5	-3.3 [-5.9, -0.6]*	1343 / 1344
CrowdPose val	左膝	v=2	13.0	12.1	-0.9 [-3.9, 2.1]	576 / 577
CrowdPose val	左膝	v=1	28.1	27.3	-0.8 [-4.7, 3.0]	1081 / 1086
CrowdPose val	右膝	v=2	13.2	11.5	-1.8 [-4.6, 1.0]	571 / 571
CrowdPose val	右膝	v=1	28.9	26.4	-2.6 [-6.6, 1.6]	1095 / 1099
OCHuman test	左肘	v=2	37.2	33.9	-3.2 [-6.2, -0.3]*	1848 / 1850
OCHuman test	左肘	v=1	54.7	52.0	-2.8 [-7.4, 1.7]	690 / 708
OCHuman test	右肘	v=2	35.9	33.4	-2.5 [-5.6, 0.5]	1855 / 1849
OCHuman test	右肘	v=1	56.0	51.6	-4.4 [-9.2, 0.5]	659 / 687
OCHuman test	左膝	v=2	21.0	18.0	-3.0 [-5.8, -0.2]*	1428 / 1453
OCHuman test	左膝	v=1	36.7	31.1	-5.7 [-12.2, 0.9]	358 / 377
OCHuman test	右膝	v=2	22.3	20.4	-1.9 [-4.9, 1.2]	1435 / 1449
OCHuman test	右膝	v=1	37.0	34.7	-2.4 [-9.1, 4.5]	375 / 402

单位：图像，逐模型独立重采样（各模型的图像集只含该关节、该层至少有一个有效实例的图像）；末列 n_{img}：ViTPose-B / ViTPose-L。10,000 次重采样，seed 42，95% 百分位 CI。

表 A8

检测器无关 ORACLE 协议下 YOLO 模型对的 M1 逐层 AP 比较（BOOTSTRAP CI）。Δ = ROUND5-3-ORACLE − YOLO11S-ORACLE；* CI 不含 0。

数据集	层	AP r5-3-o	AP YOLO11s-o	Δ AP [95% CI]
COCO val	full	0.4250	0.4411	-0.0161 [-0.0220, -0.0099]*
COCO val	v=2	0.4188	0.4347	-0.0159 [-0.0213, -0.0092]*
COCO val	v=1	0.0940	0.0971	-0.0030 [-0.0072, 0.0015]
CrowdPose val	full	0.5591	0.5148	0.0442 [0.0361, 0.0527]*
CrowdPose val	v=2	0.2783	0.2555	0.0228 [0.0173, 0.0288]*
CrowdPose val	v=1	0.3523	0.3201	0.0322 [0.0249, 0.0399]*
OCHuman test	full	0.3546	0.3044	0.0501 [0.0383, 0.0633]*
OCHuman test	v=2	0.3403	0.2901	0.0502 [0.0387, 0.0636]*
OCHuman test	v=1	0.1270	0.0736	0.0534 [0.0453, 0.0635]*

单位：图像（配对；oracle 协议下两模型共享同一图像总体）。点估计为配对点差；CI 来自配对 bootstrap。10,000 次重采样，seed 42，95% 百分位 CI。

2012.

[14] G. Jocher *et al.*, “Ultralytics YOLO11,” https://github.com/ultralytics/ultralytics, 2024.

[15] A. Zeng, L. Yang, X. Ju, J. Li, J. Wang, and Q. Xu, “SmoothNet: A plug-and-play network for refining human pose estimation in videos,” in *Proc. ECCV*, 2022; arXiv:2112.13715, 2022.

[16] M. Andriluka, L. Pishchulin, P. Gehler, and B. Schiele, “2D human pose estimation: New benchmark and state of the art analysis,” in *Proc. CVPR*, 2014.

[17] Y. Xu, J. Zhang, Q. Zhang, and D. Tao, “ViTPose: Simple vision transformer baselines for human pose estimation,” in *Proc. NeurIPS*, 2022; arXiv:2204.12484, 2022.

[18] A. Kuzdeuov, D. Taratynova, A. Tleuliyev, and H. A. Varol, “OpenThermalPose: An open-source annotated thermal human pose dataset and initial YOLOv8-pose baselines,” Authorea Preprints, 2024. https://github.com/Kuzdeuov/OpenThermalPose

表 A9

检测器无关 oracle 协议下的 M1 跨族逐层 AP 差（bootstrap CI）。每格 Δ = Transformer 模型 − YOLO-oracle 模型，故 Δ > 0 表示 Transformer 占优。* CI 不含 0。

数据集	层	B−r5-3-o	B−YOLO11s-o	L−r5-3-o	L−YOLO11s-o
COCO val	full	0.3426 [0.3352, 0.3543]*	0.3265 [0.3197, 0.3379]*	0.3738 [0.3637, 0.3832]*	0.3577 [0.3481, 0.3669]*
COCO val	v=2	0.3424 [0.3324, 0.3512]*	0.3265 [0.3175, 0.3355]*	0.3715 [0.3608, 0.3803]*	0.3556 [0.3461, 0.3647]*
COCO val	v=1	0.2070 [0.1966, 0.2147]*	0.2039 [0.1937, 0.2119]*	0.2350 [0.2249, 0.2440]*	0.2319 [0.2218, 0.2411]*
CrowdPose val	full	0.2769 [0.2653, 0.2884]*	0.3212 [0.3107, 0.3317]*	0.3062 [0.2933, 0.3163]*	0.3505 [0.3384, 0.3596]*
CrowdPose val	v=2	0.2122 [0.1990, 0.2241]*	0.2350 [0.2224, 0.2469]*	0.2259 [0.2134, 0.2391]*	0.2487 [0.2367, 0.2617]*
CrowdPose val	v=1	0.2417 [0.2318, 0.2519]*	0.2739 [0.2645, 0.2843]*	0.2749 [0.2650, 0.2861]*	0.3072 [0.2977, 0.3183]*
OCHuman test	full	0.1968 [0.1798, 0.2107]*	0.2469 [0.2317, 0.2604]*	0.2538 [0.2360, 0.2681]*	0.3039 [0.2875, 0.3178]*
OCHuman test	v=2	0.1985 [0.1821, 0.2132]*	0.2487 [0.2344, 0.2632]*	0.2562 [0.2401, 0.2725]*	0.3065 [0.2918, 0.3227]*
OCHuman test	v=1	0.0774 [0.0647, 0.0893]*	0.1308 [0.1196, 0.1429]*	0.1366 [0.1228, 0.1497]*	0.1900 [0.1769, 0.2038]*

单位：图像（配对；oracle 协议下四个模型共享同一图像总体）。点估计为配对点差；CI 来自配对 bootstrap。10,000 次重采样，seed 42，95% 百分位 CI。

表 A10

检测器无关 oracle 协议下 PoseTrack18 val 的 M3 跨族时序指标差（bootstrap CI）。Δ = Transformer 模型 − YOLO-oracle 模型，故 Δ < 0 表示 Transformer 占优（抖动更低）。* CI 不含 0。

比较	指标	Δ [95% CI]
ViTPose-B − r5-3-o	$\bar{d}$	-0.0052 [-0.0092, -0.0009]*
ViTPose-B − r5-3-o	d_{95}	-0.0136 [-0.0275, 0.0006]
ViTPose-B − r5-3-o	$\text{jump}_{0.05}$	-0.0581 [-0.0800, -0.0355]*
ViTPose-B − r5-3-o	$\text{jump}_{0.10}$	-0.0176 [-0.0306, -0.0045]*
ViTPose-B − YOLO11s-o	$\bar{d}$	-0.0074 [-0.0118, -0.0030]*
ViTPose-B − YOLO11s-o	d_{95}	-0.0188 [-0.0337, -0.0040]*
ViTPose-B − YOLO11s-o	$\text{jump}_{0.05}$	-0.0675 [-0.0904, -0.0446]*
ViTPose-B − YOLO11s-o	$\text{jump}_{0.10}$	-0.0232 [-0.0372, -0.0097]*
ViTPose-L − r5-3-o	$\bar{d}$	-0.0056 [-0.0101, -0.0010]*
ViTPose-L − r5-3-o	d_{95}	-0.0184 [-0.0323, -0.0045]*
ViTPose-L − r5-3-o	$\text{jump}_{0.05}$	-0.0629 [-0.0850, -0.0413]*
ViTPose-L − r5-3-o	$\text{jump}_{0.10}$	-0.0209 [-0.0340, -0.0081]*
ViTPose-L − YOLO11s-o	$\bar{d}$	-0.0078 [-0.0126, -0.0029]*
ViTPose-L − YOLO11s-o	d_{95}	-0.0236 [-0.0381, -0.0091]*
ViTPose-L − YOLO11s-o	$\text{jump}_{0.05}$	-0.0723 [-0.0958, -0.0492]*
ViTPose-L − YOLO11s-o	$\text{jump}_{0.10}$	-0.0266 [-0.0403, -0.0128]*

单位：轨迹段（配对；oracle 协议下匹配口径段，每个 GT 标注一个预测）。10,000 次重采样，seed 42，95% 百分位 CI。

表 A11

检测器无关 oracle 协议下 YOLO 模型对的 M2 关节角 RMSE（°，分侧）比较（bootstrap CI）。Δ = round5-3-oracle − YOLO11s-oracle（负 = round5-3-oracle 误差更低）；* CI 不含 0。

数据集	关节	层	RMSE r5-3-o	RMSE YOLO11s-o	Δ RMSE [95% CI]	n_{img}
COCO val	左肘	v=2	27.9	29.5	-1.6 [-4.2, 1.0]	1635 / 1651
COCO val	左肘	v=1	39.6	37.0	2.5 [-5.8, 11.0]	209 / 206
COCO val	右肘	v=2	26.1	26.4	-0.3 [-2.7, 2.0]	1649 / 1667
COCO val	右肘	v=1	43.6	42.6	0.9 [-6.4, 8.2]	247 / 249
COCO val	左膝	v=2	23.6	24.3	-0.6 [-3.8, 2.5]	1247 / 1262
COCO val	左膝	v=1	38.9	40.1	-1.3 [-12.0, 9.2]	149 / 133
COCO val	右膝	v=2	23.7	24.8	-1.1 [-4.1, 1.7]	1225 / 1238
COCO val	右膝	v=1	39.2	36.7	2.6 [-5.7, 11.1]	173 / 160
CrowdPose val	左肘	v=2	29.0	30.1	-1.0 [-4.2, 2.1]	770 / 768
CrowdPose val	左肘	v=1	32.8	35.8	-3.0 [-5.5, -0.4]*	1269 / 1252
CrowdPose val	右肘	v=2	26.8	27.5	-0.7 [-3.6, 2.2]	786 / 785
CrowdPose val	右肘	v=1	33.4	35.3	-1.9 [-4.5, 0.8]	1300 / 1278
CrowdPose val	左膝	v=2	24.4	26.8	-2.5 [-6.6, 1.5]	552 / 549
CrowdPose val	左膝	v=1	32.7	34.8	-2.1 [-5.6, 1.4]	1038 / 997
CrowdPose val	右膝	v=2	24.7	27.4	-2.7 [-6.5, 1.1]	553 / 546
CrowdPose val	右膝	v=1	32.2	35.5	-3.4 [-6.9, 0.1]	1038 / 1002
OCHuman test	左肘	v=2	38.4	40.3	-1.8 [-4.7, 1.0]	1725 / 1686
OCHuman test	左肘	v=1	47.4	56.6	-9.2 [-14.8, -3.6]*	511 / 460
OCHuman test	右肘	v=2	36.9	41.0	-4.1 [-7.1, -1.1]*	1748 / 1656
OCHuman test	右肘	v=1	51.0	59.2	-8.2 [-13.9, -2.6]*	478 / 459
OCHuman test	左膝	v=2	23.8	26.3	-2.5 [-5.1, 0.2]	1351 / 1296
OCHuman test	左膝	v=1	37.1	36.2	0.9 [-7.3, 8.9]	251 / 224
OCHuman test	右膝	v=2	25.1	27.6	-2.5 [-5.5, 0.5]	1356 / 1280
OCHuman test	右膝	v=1	40.0	44.0	-4.0 [-13.2, 5.1]	266 / 253

单位：图像，逐模型独立重采样（各模型的图像集只含该关节、该层至少有一个有效实例的图像）；末列 n_{img}：round5-3-oracle / YOLO11s-oracle。10,000 次重采样，seed 42，95% 百分位 CI。

表 A12

检测器无关 oracle 协议下的 M2 跨族关节角 RMSE 差（°，分侧；bootstrap CI）。每格 Δ = Transformer 模型 − YOLO-oracle 模型，故 Δ < 0 表示 Transformer 占优（误差更低）。* CI 不含 0。

数据集	关节	层	B−r5-3-o	B−YOLO11s-o	L−r5-3-o	L−YOLO11s-o
COCO val	左肘	v=2	-9.6 [-12.1, -7.2]*	-11.2 [-13.8, -8.7]*	-12.4 [-14.8, -9.9]*	-14.0 [-16.4, -11.5]*
COCO val	左肘	v=1	-10.6 [-18.6, -2.5]*	-8.0 [-15.9, -0.3]*	-11.8 [-20.4, -3.3]*	-9.2 [-17.5, -1.0]*
COCO val	右肘	v=2	-8.8 [-11.4, -6.1]*	-9.1 [-11.6, -6.5]*	-11.8 [-14.1, -9.5]*	-12.1 [-14.4, -9.9]*
COCO val	右肘	v=1	-11.0 [-18.7, -3.1]*	-10.1 [-17.6, -2.6]*	-15.4 [-23.2, -7.9]*	-14.5 [-21.9, -7.3]*
COCO val	左膝	v=2	-9.8 [-12.6, -7.0]*	-10.4 [-13.2, -7.6]*	-10.7 [-13.5, -7.9]*	-11.3 [-14.2, -8.5]*
COCO val	左膝	v=1	-5.4 [-16.2, 5.5]	-6.7 [-16.4, 2.8]	-13.7 [-23.7, -3.5]*	-15.0 [-23.7, -6.2]*
COCO val	右膝	v=2	-9.2 [-11.8, -6.6]*	-10.3 [-13.0, -7.6]*	-11.3 [-13.8, -8.8]*	-12.5 [-15.2, -9.8]*
COCO val	右膝	v=1	-5.4 [-15.1, 4.3]	-2.8 [-12.3, 6.5]	-8.1 [-17.8, 1.7]	-5.6 [-14.8, 3.7]
CrowdPose val	左肘	v=2	-14.1 [-16.7, -11.5]*	-15.2 [-17.9, -12.5]*	-14.9 [-17.7, -12.2]*	-16.0 [-18.8, -13.1]*
CrowdPose val	左肘	v=1	-1.3 [-3.8, 1.2]	-4.3 [-6.9, -1.7]*	-3.3 [-5.7, -0.9]*	-6.3 [-8.9, -3.7]*
CrowdPose val	右肘	v=2	-12.0 [-14.6, -9.3]*	-12.7 [-15.4, -10.0]*	-13.8 [-16.3, -11.3]*	-14.6 [-17.1, -12.0]*
CrowdPose val	右肘	v=1	-3.6 [-6.3, -1.0]*	-5.5 [-8.2, -2.9]*	-6.9 [-9.5, -4.4]*	-8.8 [-11.5, -6.2]*
CrowdPose val	左膝	v=2	-11.4 [-14.8, -8.0]*	-13.9 [-17.4, -10.2]*	-12.3 [-15.9, -8.9]*	-14.8 [-18.3, -11.1]*
CrowdPose val	左膝	v=1	-4.5 [-8.1, -0.9]*	-6.7 [-10.3, -3.1]*	-5.4 [-9.0, -1.7]*	-7.5 [-11.1, -3.8]*
CrowdPose val	右膝	v=2	-11.5 [-14.8, -8.1]*	-14.2 [-17.5, -10.8]*	-13.3 [-16.5, -10.1]*	-16.0 [-19.2, -12.6]*
CrowdPose val	右膝	v=1	-3.2 [-6.9, 0.4]	-6.6 [-10.5, -2.9]*	-5.8 [-9.7, -2.0]*	-9.2 [-13.1, -5.1]*
OCHuman test	左肘	v=2	-1.3 [-4.2, 1.6]	-3.1 [-5.9, -0.2]*	-4.5 [-7.4, -1.6]*	-6.3 [-9.2, -3.4]*
OCHuman test	左肘	v=1	7.4 [2.4, 12.5]*	-1.8 [-7.2, 3.5]	4.6 [-0.4, 9.5]	-4.6 [-10.0, 0.8]
OCHuman test	右肘	v=2	-1.0 [-4.1, 2.2]	-5.1 [-8.1, -2.1]*	-3.5 [-6.6, -0.5]*	-7.6 [-10.7, -4.6]*
OCHuman test	右肘	v=1	4.9 [-0.4, 10.3]	-3.3 [-8.4, 2.0]	0.6 [-4.6, 5.9]	-7.6 [-12.9, -2.4]*
OCHuman test	左膝	v=2	-2.8 [-5.6, -0.0]*	-5.3 [-8.0, -2.5]*	-5.8 [-8.4, -3.1]*	-8.2 [-11.0, -5.6]*
OCHuman test	左膝	v=1	-0.3 [-7.7, 7.4]	0.6 [-7.1, 8.4]	-6.0 [-13.1, 1.1]	-5.1 [-12.4, 2.2]
OCHuman test	右膝	v=2	-2.8 [-5.8, 0.1]	-5.3 [-8.3, -2.3]*	-4.7 [-7.7, -1.8]*	-7.2 [-10.3, -4.1]*
OCHuman test	右膝	v=1	-3.0 [-10.7, 4.9]	-7.0 [-15.5, 1.5]	-5.3 [-12.9, 2.5]	-9.3 [-17.4, -0.9]*

单位：图像，逐模型独立重采样（各模型的图像集只含该关节、该层至少有一个有效实例的图像）。10,000 次重采样，seed 42，95% 百分位 CI。

表 A13

检测协议下各模型 M2 关节角 RMSE（°，分侧）v=1−v=2 层差的配对 bootstrap CI。$\Delta = \mathrm{RMSE}(v{=}1) - \mathrm{RMSE}(v{=}2)$，$\Delta > 0$ 表示遮挡层误差更高；* CI 不含 0。

模型	数据集	关节	RMSE v=1	RMSE v=2	Δ RMSE [95% CI]	n_{img}
r5-3	COCO val	左肘	33.5	27.0	6.5 [1.2, 11.8]*	248 / 1720
r5-3	COCO val	右肘	37.7	24.9	12.8 [8.0, 17.5]*	290 / 1732
r5-3	COCO val	左膝	30.8	20.3	10.5 [3.4, 17.2]*	180 / 1320
r5-3	COCO val	右膝	27.7	20.5	7.2 [0.2, 14.2]*	202 / 1302
r5-3	CrowdPose val	左肘	31.3	27.5	3.8 [1.3, 6.4]*	1319 / 790
r5-3	CrowdPose val	右肘	31.9	24.1	7.8 [5.6, 10.1]*	1343 / 810
r5-3	CrowdPose val	左膝	25.7	21.1	4.5 [1.4, 7.7]*	1085 / 575
r5-3	CrowdPose val	右膝	26.2	20.0	6.2 [3.2, 9.1]*	1104 / 570
r5-3	OCHuman test	左肘	45.4	35.6	9.9 [6.6, 13.1]*	860 / 1931
r5-3	OCHuman test	右肘	46.0	35.6	10.4 [7.0, 13.7]*	822 / 1935
r5-3	OCHuman test	左膝	30.7	24.4	6.3 [2.5, 10.0]*	498 / 1507
r5-3	OCHuman test	右膝	33.3	24.2	9.1 [4.6, 13.3]*	525 / 1499
YOLO11s	COCO val	左肘	36.6	26.3	10.3 [4.1, 16.4]*	247 / 1727
YOLO11s	COCO val	右肘	34.8	24.5	10.3 [5.6, 15.1]*	292 / 1730
YOLO11s	COCO val	左膝	32.2	20.9	11.3 [3.3, 18.8]*	182 / 1325
YOLO11s	COCO val	右膝	30.3	21.2	9.1 [2.2, 15.9]*	205 / 1306
YOLO11s	CrowdPose val	左肘	35.0	27.3	7.7 [5.3, 10.2]*	1321 / 793
YOLO11s	CrowdPose val	右肘	35.0	24.6	10.4 [7.8, 12.9]*	1338 / 811
YOLO11s	CrowdPose val	左膝	30.5	21.3	9.2 [6.0, 12.4]*	1081 / 575
YOLO11s	CrowdPose val	右膝	30.5	21.2	9.3 [6.5, 12.2]*	1096 / 571
YOLO11s	OCHuman test	左肘	56.2	39.7	16.5 [13.1, 19.8]*	871 / 1951
YOLO11s	OCHuman test	右肘	59.2	39.5	19.7 [16.3, 23.0]*	831 / 1947
YOLO11s	OCHuman test	左膝	39.5	28.0	11.4 [7.1, 15.8]*	499 / 1514
YOLO11s	OCHuman test	右膝	39.9	28.5	11.4 [6.9, 15.8]*	534 / 1503

单位：图像，并集图像集上的配对重采样（每次重采样对两层施加同一组索引）；并集指该关节在任一层的有效实例图像。末列 n_{img}：v=1 / v=2 层图像数。10,000 次重采样，seed 42，95% 百分位 CI。

表 A14

核心比较族的 Benjamini–Hochberg FDR 敏感性分析（round5-3 对 YOLO11s-pose）。Δ = round5-3 − YOLO11s-pose：$\Delta > 0$ 对 AP（F1）表示 round5-3 占优，对 RMSE 与抖动（F2、F3）表示 YOLO11s-pose 占优。

Family	Comparison	Δ	95% CI	p	p_{BH}
F1 M1 全量 AP (n=3; raw sig 3; BH sig 3)					
	COCO val	-0.0104	[-0.0155, -0.0059]	0.0000	0.0000*
	CrowdPose val	0.0687	[0.0616, 0.0754]	0.0000	0.0000*
	OCHuman test	0.1396	[0.1281, 0.1508]	0.0000	0.0000*
F2 M2 逐格 RMSE（度）(n=24; raw sig 12; BH sig 11)					
	COCO val 左肘 v=2	0.6782	[-1.7287, 3.0396]	0.5828	0.8322
	COCO val 左肘 v=1	-3.0933	[-11.0757, 4.7844]	0.4440	0.7611
	COCO val 右肘 v=2	0.4619	[-1.8765, 2.7743]	0.7022	0.8322
	COCO val 右肘 v=1	2.8784	[-3.4155, 9.1133]	0.3736	0.6897
	COCO val 左膝 v=2	-0.5693	[-3.1142, 1.9829]	0.6554	0.8322
	COCO val 左膝 v=1	-1.3997	[-11.5768, 8.8087]	0.7992	0.8719
	COCO val 右膝 v=2	-0.7424	[-3.1356, 1.6546]	0.5548	0.8322
	COCO val 右膝 v=1	-2.6246	[-12.1749, 6.9116]	0.6016	0.8322
	CrowdPose val 左肘 v=2	0.2177	[-2.5063, 2.9847]	0.8768	0.9149
	CrowdPose val 左肘 v=1	-3.7355	[-6.0494, -1.4487]	0.0016	0.0055*
	CrowdPose val 右肘 v=2	-0.5567	[-3.1789, 2.0759]	0.6718	0.8322
	CrowdPose val 右肘 v=1	-3.0991	[-5.4989, -0.7193]	0.0086	0.0188*
	CrowdPose val 左膝 v=2	-0.2008	[-3.6422, 3.3487]	0.9206	0.9206
	CrowdPose val 左膝 v=1	-4.8695	[-7.6710, -2.0897]	0.0002	0.0016*
	CrowdPose val 右膝 v=2	-1.1955	[-4.3292, 2.0215]	0.4630	0.7611
	CrowdPose val 右膝 v=1	-4.3532	[-7.2435, -1.4274]	0.0030	0.0080*
	OCHuman test 左肘 v=2	-4.1708	[-6.5563, -1.7360]	0.0008	0.0038*
	OCHuman test 左肘 v=1	-10.8007	[-14.5977, -6.8819]	0.0000	0.0000*
	OCHuman test 右肘 v=2	-3.9219	[-6.4280, -1.4694]	0.0016	0.0055*
	OCHuman test 右肘 v=1	-13.2385	[-17.1184, -9.2323]	0.0000	0.0000*
	OCHuman test 左膝 v=2	-3.6435	[-6.1476, -1.1277]	0.0058	0.0139*
	OCHuman test 左膝 v=1	-8.7966	[-13.8743, -3.5585]	0.0008	0.0038*
	OCHuman test 右膝 v=2	-4.3093	[-6.8603, -1.7329]	0.0004	0.0024*
	OCHuman test 右膝 v=1	-6.6124	[-12.3613, -0.7771]	0.0264	0.0528
F3 M3 时序指标（PoseTrack val）(n=7; raw sig 0; BH sig 0)					
	位移均值	-0.0022	[-0.0062, 0.0018]	0.3004	1.0000
	抖动均值	-0.0014	[-0.0075, 0.0047]	0.6510	1.0000
	位移 P95	-0.0051	[-0.0182, 0.0078]	0.4478	1.0000
	抖动 P95	-0.0050	[-0.0273, 0.0178]	0.6816	1.0000
	跳变率 τ=0.05	-0.0091	[-0.0326, 0.0147]	0.4490	1.0000
	跳变率 τ=0.10	-0.0051	[-0.0188, 0.0085]	0.4688	1.0000
	跳变率 τ=0.20	-0.0032	[-0.0078, 0.0015]	0.1828	1.0000

* 族内 BH 校正后 $p < 0.05$。p：双侧 bootstrap $(2\min(P(\Delta \le 0), P(\Delta \ge 0)))$，10,000 次重采样，seed 42；显著性以 95% CI 是否含 0 判定。F1：配对图像域（两模型 GT 与预测图并集）；F2：图像级独立重采样；F3：轨迹段级独立重采样。raw sig 为 BH 校正前 CI 不含 0 的比较数。

表 A15

检测协议下 YOLO 模型对的 M2 关节角 MAE 与 P95（°，分侧），按顶点关节 GT 可见性分层。MAE = $|e|$ 的均值；P95 = $|e|$ 的 95 百分位；$e = \theta_{\text{pred}} - \theta_{\text{gt}}$（RMSE 一并列出，与表 A11 及表 2 互查）。

数据集	关节	层	MAE r5-3	P95 r5-3	MAE YOLO11s	P95 YOLO11s	n
COCO val	左肘	v=2	15.8	57.0	15.7	54.6	3148 / 3166
COCO val	左肘	v=1	21.4	69.7	22.8	85.7	293 / 297
COCO val	右肘	v=2	14.4	52.4	14.5	52.6	3125 / 3136
COCO val	右肘	v=1	24.4	94.5	22.6	77.6	356 / 355
COCO val	左膝	v=2	11.5	40.9	12.1	41.8	2513 / 2523
COCO val	左膝	v=1	17.0	75.3	17.5	69.0	207 / 209
COCO val	右膝	v=2	11.5	40.0	12.3	41.1	2467 / 2474
COCO val	右膝	v=1	16.1	57.5	17.7	69.6	230 / 231
CrowdPose val	左肘	v=2	16.2	59.5	16.3	59.8	2019 / 2022
CrowdPose val	左肘	v=1	19.2	71.2	21.8	87.1	2925 / 2896
CrowdPose val	右肘	v=2	14.8	51.7	14.9	51.8	1983 / 1991
CrowdPose val	右肘	v=1	19.2	73.3	21.4	85.0	2971 / 2937
CrowdPose val	左膝	v=2	11.6	45.0	12.3	44.6	1538 / 1537
CrowdPose val	左膝	v=1	14.2	57.3	18.0	70.6	2270 / 2234
CrowdPose val	右膝	v=2	10.9	37.4	12.0	39.3	1466 / 1468
CrowdPose val	右膝	v=1	14.0	54.9	17.6	70.6	2286 / 2250
OCHuman test	左肘	v=2	22.2	86.8	25.1	96.4	2634 / 2675
OCHuman test	左肘	v=1	33.6	96.8	42.7	120.0	905 / 915
OCHuman test	右肘	v=2	22.1	85.3	25.1	98.2	2672 / 2712
OCHuman test	右肘	v=1	33.8	99.7	45.3	120.8	854 / 865
OCHuman test	左膝	v=2	14.1	54.6	16.9	60.6	2130 / 2167
OCHuman test	左膝	v=1	19.4	67.4	25.5	87.6	532 / 532
OCHuman test	右膝	v=2	13.9	53.9	16.8	66.2	2100 / 2126
OCHuman test	右膝	v=1	19.2	83.7	24.2	104.2	558 / 566

单位：实例。末列 n：有效实例数，r5-3 / YOLO11s-pose。